

I 教育背景

武汉大学 网络空间安全, GPA: 3.89/4.0, 综合排名: 6/172

2023.09– 2027.06

- 核心课程: 高等数学 A1(91)、线性代数 A(95)、概率论与数理统计 A(93)、信息安全数学基础 (98)、大学物理 B 上 (98)、大数据处理技术 (96)、计算机网络 (94)、密码学 (96,93)、数据库系统及安全 (95)、网络安全 (94,95)、内容安全 (94,91)、软件逆向分析 (92)、自然语言处理 (91,97)、信息检索技术 (97)、社会计算 (94)、安全创客实践 (100)
- 编程能力: 掌握 C/C++、Python、 $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ 等编程语言, 具备良好的算法设计与工程实现能力; 熟悉主流深度学习框架 PyTorch, 能够基于其构建神经网络模型并完成训推流程; 熟练使用 Numpy、Pandas、Matplotlib 等常用科学计算与数据分析库, 能够高效进行数据预处理、可视化与批量操作; 在多个项目中完成模型搭建、调试与优化。
- 语言能力: 通过四六级, 其中英语六级 599 分, 有独立完成全英学术论文写作投稿的经验, 英语能力满足学术需求
- 奖项荣誉: ARC Prize 国际级铜牌、中国机器人及人工智能大赛国家级一等奖 $\times 2$ 、全国大学生信息安全竞赛国家级二等奖、高校计算机大赛-网络技术挑战赛国家级二等奖、中国大学生计算机设计大赛国家级二等奖、武汉大学三好学生

I 科研经历 【人工智能安全与隐私、图学习、协作学习、模型合并】

🔗 [已完成] 用于单轮个性化联邦图学习的传播感知协作校准范式

已投稿于 AAAI 2027 | 共同第一作者

- 研究方向: 隐私安全、联邦学习、图神经网络、协作学习
- 研究背景: (1) 图数据通常以相互关联的本地子图形式分布式存在于不同机构或设备中, 联邦图学习 (FGL) 能够在不直接汇总节点、边与标签等原始私有数据的前提下实现跨客户端协作建模; (2) 在子图存在结构异质性的场景下, 单轮个性化联邦图学习 (One-Shot FGL) 旨在通过仅一次通信吸收有益的跨客户端知识, 同时保留特定社区的本地个性化表征; (3) 然而单轮通信面临着严峻挑战: 在极轻量的低秩传输预算下难以完整压缩并保留不同客户端间互补的图传播模式与表征证据, 跨异质社区盲目融合又极易引发负向迁移, 且无法依赖后续轮次反馈来修正错误聚合; (4) 目前亟需一种能够兼顾传播感知低秩传输与接收方自适应选择性吸收的单轮个性化联邦图学习范式。
- 我们的方法: (1) 提出了 PACE 框架, 首个无需图数据合成的单轮个性化联邦图学习范式, 将传播感知低秩模型传输与接收方本地凸负对数似然校准 (CNLL) 相结合, 在无需后处理模型优化与额外通信的条件下实现了选择性正向跨客户端知识迁移; (2) 【轻量传播感知传输】: 客户端仅需独立训练并上传一次经 SVD 截断压缩的 Rank-6 模型更新载体以及由图卷积传播消息构成的二阶矩传播草图; 服务器据此求解自包含的 RegMean 传播感知共识, 并生成针对性的接收方锚定低秩修正项返回给客户端; (3) 【接收方自适应凸校准】: 接收方将返回的修正项作为可选外部预测器, 仅利用本地验证集求解一个一维凸负对数似然校准问题, 自适应调整本地 Logit 与外部 Logit 的混合系数 α ; (4) 该设计完整保留了接收方的原始本地模型与独立预测能力, 在外部知识有效时实现高增益吸收, 而在知识冲突时可无损精确回退至纯本地模型, 将单向传输通信开销大幅降低至密集模型的 10%–17%。
- 实验效果: 针对 6 个主流图基准数据集与 9 种代表性 Baseline 进行了全面实验; 结果表明 PACE 均取得了最佳的 Accuracy 与 Weighted-F1 性能, 实现了显著的自适应正向迁移; 在相同校准基准对比实验中持续保持领先, 证明了其在保持极低通信开销的同时实现安全高效知识吸收的独到优势。
- 科研成果: 相关论文已投稿于 AAAI 2027 (CCF-A 类会议) (我作为共同第一作者)。

[已完成] 基于协同权重扰动的模型合并突发性安全失效

进行中 | 共同第一作者

- 研究方向: 人工智能安全、模型合并安全
- 研究背景: (1) 模型合并 (Model Merging) 能够有效聚合多个专家模型的专业能力, 已成为大模型高效部署的重要范式; (2) 然而模型合并过程会破坏对齐机制并引入全新的攻击面, 导致单体安全的模型在合并后产生安全漏洞; (3) 现有研究缺乏对合并算法与安全机制相互作用的系统性分析, 尤其是在模型开源分发场景下, 攻击者能否设计单体看似无害但合并后即触发恶意行为的源模型仍属未知; (4) 现有后门攻击方法 (BadMerging、MergeHijacking) 高度依赖特定的输入

触发词或图像补丁，极易被现有的检测防御机制识别；(5) 因此，目前亟需一种能够揭示模型合并内在机制缺陷、在无需显式触发词的前提下评估与挖掘合并模型潜在安全风险的系统性范式。

- 我们的方法：提出了首个针对大模型合并安全漏洞的隐蔽攻击框架，将合并诱导的安全失配形式化为隐蔽攻击组件的约束优化问题，在保持源模型单体安全性与基础能力的同时实现合并后的定向安全失配；(1) 【方向一致性约束】：确保恶意输入下修改前后激活向量的余弦相似度接近 1，维持源模型的拒答行为；(2) 【Frobenius 空间方向一致性与正交条件】：约束攻击组件与原始权重的方向，最大程度降低对模型领域专家能力的干扰；(3) 【目标安全失配与攻击重构】：基于模型编辑技术提取安全关键变换 (SCT) ΔW ，并施加硬性参数级约束，确保多个源模型中隐蔽植入的扰动组件在通过加权平均融合时，能够精准重构出预计算的攻击向量；(4) 我们的方案可以实现无需显式触发词的隐蔽木马植入，使源模型能够顺利通过单体安全与能力评估，而在融合后自动触发突发性安全对齐崩溃。
- 科研成果：目前正在验证性实验，预计投稿于 USENIX Security 2027 (CCF-A) (我作为共同第一作者)。

I 竞赛经历【主要围绕 人工智能安全 方向】

🏆 [已完成] 利用头部振动反馈的隐式身份验证系统

CRAIC · 全国一等奖 | 队长

- 研究方向：人工智能安全、身份认证安全
- 研究背景：现有耳戴设备认证主要针对入耳式耳机，普遍依赖封闭耳道与用户主动交互，这不仅打断正常使用流程，且难以适应骨传导开放式佩戴与振动传导特性。目前亟需兼顾高安全与无感体验的隐式认证新方案。
- 我们的方法：本文提出通过头部接触响应实现隐式验证：(1) 低干扰探测机制：调制扫频 Chirp 信号并结合听力特性频域抑制，显著降低听感扰动；(2) 双维特征提取：引入头部阻抗与结构不对称特征组合建模，增强个体解剖判别力；(3) 小样本迁移学习：基于轻量化 Siamese 架构进行快速微调，仅需 10 个样本即可构建模板，大幅减轻用户注册负担；(4) 自适应模型更新：采用先进先出机制在线引入合法样本重训网络，有效对抗特征随时间老化难题。
- 比赛成果：中国机器人及人工智能大赛（全国总决赛）：国家级一等奖。

🏆 [已完成] 基于“双盾双溯源”的视觉语言模型全链路版权保护体系

CRAIC · 全国一等奖 | 核心队员

- 研究方向：人工智能安全、模型水印、视觉语言模型
- 研究背景：现有的跨模态版权保护方案普遍割裂：要么无法抵抗微调剪枝等恶意移除攻击，要么数字水印的信息容量极其有限且严重牺牲生成内容的流畅度。亟需一种能够同时覆盖模型所有权与内容产出物的全链路双层防护新范式。
- 我们的方法：本文提出 MaskSource，一个全链路多模态版权保护体系：(1) 双密钥联合触发：利用小波变换与可逆网络编码视觉无损图像，配合提示语双重校验，根除单触发器误激活与决策边界崩溃漏洞；(2) 多任务联合优化：引入多梯度下降算法平衡梯度冲突，在遭受高频对抗梯度攻击时使秘密重建误差强力降低超 70%；(3) 熵引导自适应嵌入：计算词元预测香农熵，将身份序列动态注入高熵隐写空间，嵌入容量大幅提升至 2.0-4.0 bits/token；(4) 多列表高保真采样：拓展红绿列表机制进行带权采样，在维持高检测率的同时将文本困惑度逆势优化至个位数水平。
- 比赛成果 1：中国机器人及人工智能大赛（全国总决赛）：国家级一等奖。
- 比赛成果 2：高校计算机大赛-网络技术挑战赛（全国总决赛）：国家级三等奖。

🏆 [已完成] 面向语音克隆滥用的声纹隐私保护系统

计设赛/CCCC · 全国二等奖 | 核心队员

- 研究方向：人工智能安全、内容安全、深度伪造
- 研究背景：生成式 AI 的发展使得语音克隆技术门槛大幅降低，带来了诸多风险。现有防御机制主要依赖事后检测等被动手段，这在未知伪造或有损信道下鲁棒性严重低且极度滞后。目前虽有初步的主动防御尝试，但普遍存在防御语音抗克隆能力弱、音频保真度低、跨模型泛化性差等严重缺陷。亟需构建一种鲁棒隐私的主动防御新范式。
- 我们的方法：本文开发了统一的多层次主动防御系统，从源头遏制声纹隐私泄露：(1) 匿名异性身份替换：提出基于 KL 散度的声纹特征选择算法，自适应选取差异最显著的异性聚类中心进行加权合成，从根本上斩断攻击者复现 victim 音色的可能；(2) 高斯扰动波形优化：采用高斯噪声优化的 WaveGlow 对抗语音生成架构，引入高斯分布逼近损失与软约束损失，确保对抗扰动与防御音频共享统计特性以在波形层面维持听感保真；(3) 自适应动态集成攻击：设计动态权重调整的集成说话人编码器策略，归一化各模型损失尺度的内在差异，并结合锐度感知最小化 (SAM) 与梯度正则化技术全面提升扰动在未知合成器之间的可转移性。
- 比赛成果 1：中国大学生计算机设计大赛（全国总决赛）：国家级二等奖。
- 比赛成果 2：高校计算机大赛-网络技术挑战赛（全国总决赛）：国家级二等奖。

 [已完成] 基于时序因果诊断与上下文净化的 OpenClaw 动态防火墙

信安大赛 · 全国二等奖 | 核心队员

- 研究方向：人工智能安全、智能体安全、提示词注入防御
- 研究背景：(1) 工具型智能体能够调用邮件、文件、命令行等工具执行真实操作，安全问题由“模型说什么”转向“模型做什么”；(2) 外部网页、邮件等内容中的间接提示词注入可能经多轮上下文传播，诱导智能体执行未经用户授权的操作；(3) 现有文本过滤与静态权限控制难以兼顾风险阻断与事实保留，因此亟需面向工具执行链的动态授权机制。
- 我们的方法：(1) 提出面向 OpenClaw 工具执行链的操作级动态防火墙，将来源追踪、因果诊断、上下文净化与执行门控嵌入运行流程，将安全判断从“文本是否可疑”推进到“操作是否获得用户授权”；(2) 设计四路反事实重放的时序因果诊断，通过原始、遮蔽、净化和遮蔽净化视图的动作差异，量化低可信外部载体对候选操作的因果影响；(3) 进一步采用事实保留、行动降权、控制剥离的上下文净化策略，并结合细粒度授权检查，在工具执行前完成放行、确认或阻断；(4) 从而实现阻断越权操作的同时保留正常任务所需事实，并形成可审查、可复验的安全证据链。
- 比赛成果：中国大学生信息安全竞赛（全国总决赛）：国家级二等奖。

 [已完成] 基于掩码扩散与自适应推理的少样本视觉逻辑求解系统

ARC Prize 2025 · 铜牌 | 核心队员

- 研究方向：少样本视觉逻辑推理、扩散模型
- 比赛背景：(1) 赋予模型极少样本下的抽象认知与逻辑推理能力是迈向 AGI 的核心挑战；(2) ARC 基准测试要求在严苛算力与时间限制下完成未知的复杂网格变换任务；(3) 该领域的关键挑战在于：数据极度匮乏（仅约 3 个示例）且测试集存在巨大分布偏移（OOD）；(4) 传统自回归大模型极易过拟合，将网格展平为一维文本会严重丢失空间依赖，且缺乏动态纠错能力；(5) 亟需一种具备强空间感知与动态自适应推理的新范式，以突破泛化瓶颈。
- 我们的方法：提出一种融合二维掩码扩散与动态增强推理的高效复合架构：【一. Skill-Mix 数据合成与抗干扰训练】：(1) 利用大模型融合基础逻辑算子，自动合成海量复杂变种任务以缓解数据匮乏；(2) 引入 BPE 分词丢弃 (Dropout) 机制进行随机正则化，大幅提升对未知输入格式的鲁棒性；【二. 融合二维位置编码的掩码扩散模型】：(3) 构建掩码扩散语言模型 (Masked Diffusion LLM)，将网格生成转化为连续迭代采样的掩码还原过程；(4) 结合二维位置编码，赋予模型全局统筹、自我纠错及精准捕获空间拓扑依赖的能力；【三. 基于 AIRV 的测试时训练 (TTT)】：(5) 推理时对极少示例进行几何变换以动态微调底座模型，并将预测结果反向变换后集成投票 (Vote)；(6) 该设计有效消除视角方差，构建了动态的空间感知与自适应推理范式，确保模型在复杂变换中的全局准确性。
- 比赛成果：在参与 ARC Prize 2025 全球挑战赛的 1456 个团队中排名前 8%，斩获了一枚铜牌。

 荣誉获奖

● 国际级铜牌	ARC Prize 2025	2025 年
● 国家级一等奖	中国机器人及人工智能大赛（骨振）	2026 年
● 国家级一等奖	中国机器人及人工智能大赛（MaskSource）	2026 年
● 国家级二等奖	全国大学生信息安全竞赛	2026 年
● 国家级二等奖	中国大学生计算机设计大赛	2026 年
● 国家级二等奖	高校计算机大赛-网络技术挑战赛（用声无恙）	2026 年
● 国家级三等奖	高校计算机大赛-网络技术挑战赛（MaskSource）	2026 年
● 湖北赛区一等奖	中国机器人及人工智能大赛	2026 年
● 中南地区赛一等奖	中国大学生计算机设计大赛	2026 年
● 中南地区赛一等奖	中国大学生计算机设计大赛	2026 年
● 华中赛区一等奖	高校计算机大赛-网络技术挑战赛	2026 年
● 湖北赛区二等奖	中国机器人及人工智能大赛	2026 年
● 中南地区赛二等奖	中国大学生计算机设计大赛	2026 年
● 华中赛区二等奖	高校计算机大赛-网络技术挑战赛	2026 年