

用声无恙



面向语音克隆滥用的声纹隐私保护系统



声纹保护



隐私安全



滥用防御



可信可控

守护每一种声音，守住每一份隐私

作品设计文档

对应文档页码： P3 到 P76

目录

摘要.....	1
第一章 作品概述.....	3
1.1 选题背景.....	3
1.2 相关工作.....	6
1.2.1 语音克隆伪造	6
1.2.2 说话人编码器	8
1.2.3 语音克隆防御	9
1.3 特色描述.....	11
1.4 应用前景分析	14
第二章 作品设计与实现	15
2.1 系统功能与界面	15
2.1.1 系统主页	16
2.1.2 音频防御功能	16
2.1.3 视频防御功能	17
2.1.4 音视频防御测试功能.....	18
2.2 系统工作流程	19
2.2.1 用户操作端.....	20
2.2.2 后台处理端.....	20
2.2.3 结果输出端.....	22
2.3 关键技术原理与实现.....	22
2.3.1 算法总体概述	22
2.3.2 基于匿名异性身份替换的声纹隐私主动防御	23
2.3.3 高斯扰动优化的 WaveGlow 对抗语音生成.....	28
2.3.4 动态权重调整的集成说话人编码器策略	32
2.3.5 基于梯度正则化和锐度感知最小的扰动优化	36
2.3.6 面向社交媒体的音视频主动防御系统实现	38
第三章 作品测试与分析	40
3.1 测试环境.....	40
3.1.1 设备环境.....	40
3.1.2 数据集.....	41
3.1.3 评估指标	42
3.1.4 测试模型选取	45
3.2 保真度与抗克隆能力测试	46
3.2.1 客观评估	47

3.2.2 主观评估	49
3.2.3 扰动程度 ϵ 影响	51
3.3 泛化性测试.....	52
3.4 鲁棒性测试.....	53
3.5 系统测试分析	58
第四章 创新性说明.....	61
4.1 创新性	61
4.2 实用性	63
第五章 总结	64
5.1 工作总结	64
5.2 下一步计划	65
第六章 团队成员在成果中的贡献	66
参考文献	68

摘要

随着语音伪造技术的飞速发展，金融欺诈、舆论引导等案件层出不穷。据奇安信集团对外发布的《2024 人工智能安全报告》显示，2022 年基于 AI 的深度伪造欺诈在美国造成了 **26 亿美元** 的损失；同时，仅过去的一年时间里，包括拜登、小马科斯、泽连斯基等多个国家政要被恶意伪造视频上传至公共平台，造成国际舆论形势紧张。因此，防止语音被不正当地转换和利用具有重大的现实意义。

为了应对这一不断演变的威胁，语音伪造防御技术飞速发展，大致分为被动防御和主动防御两部分。被动防御主要指伪造语音检测技术，虽然其性能随研究进展提升，但在未知伪造或编码变换情境下鲁棒性严重下滑，提升方式也较为被动；主动防御通过在语音中添加对抗扰动，预先破坏语音伪造模型的有效性，从而防止语音被恶意伪造。现有的语音伪造主动防御技术如 AntiFake, Defend your voice 等，普遍存在**防御语音的抗克隆能力弱、防御后语音的保真度低、鲁棒性弱（尤其是在压缩、加噪、重采样等常见语音处理手段下）、泛化性差**的问题。

针对这样的现状，我们团队开发了 UnVoiceClone：面向生成式伪造语音欺骗的鲁棒主动防御系统。旨在通过预先添加鲁棒性扰动破坏语音伪造模型的有效性，从源头遏制语音伪造的发生，降低声纹信息被恶意用于 AI 欺诈及舆论引导的风险。

本作品的**创新性**体现在以下四个方面：

(1) 通过异性身份替换的声纹隐私主动防御技术提升防御语音的抗克隆能力

针对现有防御技术中伪造语音与原始语音相似度高及可能的第三方声纹隐私泄露问题，本作品关注防御语音的抗克隆能力（以防御语音克隆后与真实语音的“差异性”来度量）提升，提出了**基于 KL 散度的声纹特征选择算法，结合异性身份特征替换和基音可控调节**。通过选取 KL 散度聚类中与原始语音差异最大的三个不同性别的聚类中心并调节基音，提高了声纹的区分度和唯一性。测试数据显示，在黑盒模型下，伪造语音和真实目标语音的 PSD 值（感知说话人不相似度）平均为 **3.71**，较 emb attack 和 AntiFake 方法分别增加了 **2.32** 和 **1.76**。

(2) 基于高斯分布逼近损失和软约束损失提升防御语音的保真度

针对现有技术中防御语音存在较大背景噪声导致人耳听感下降的问题，本作品采用了**高斯分布逼近损失和软约束损失**。通过高斯分布逼近损失，使防御语音在波形层面上与原始语音保持分布一致性，这不仅保证了鲁棒性，也提高了防御语音的保真度，并通过软约束损失进一步提高。测试数据显示，防御语音和原始语音说话人相似度平均为 **84.73%**，较 emb attack 和 AntiFake 方法分别增加了 **1.92%** 和 **10.68%**。

(3) 采用高斯噪声优化的 WaveGlow 对抗语音生成方法提升防御能力的鲁棒性

针对现有防御在现实应用场景中的加噪、裁剪、压缩和重采样等操作后会失效的

问题，本作品提出了**高斯噪声优化的 WaveGlow 对抗语音生成方法**，确保引入对抗扰动的防御语音符合高斯分布，来提高防御的鲁棒性。测试数据显示，本作品在经过重采样、剪裁、加噪、AAC 压缩和 MP3 压缩后，在黑盒模型上防御成功率平均为 **60.04%**，较 emb attack 和 AntiFake 方法分别提高了 **22.75%** 和 **18.14%**。

(4) 利用动态权重调整的集成说话人编码器与梯度正则化提升防御能力的泛化性

针对现有主动防御仅对特定模型进行针对性训练导致泛化性较低的问题，本作品提出了**动态权重调整的集成说话人编码器策略**，并引入**梯度正则和锐度感知最小化 (SAM) 技术**，通过动态集成说话人编码器及平衡模型的平滑性和梯度相似性，提升防御能力的泛化性。测试数据表明，本作品在未知黑盒模型 (LVC-VC、VALL-E、XTTS2、ElevenLabs) 场景下，防御成功率平均为 **66.29%**，较 emb attack 和 AntiFake 方法分别增加了 **20.69%**，**13.2%**。

本作品的**实用性**体现在以下三个方面：

(1) 实现了 UnVoiceClone 系统，为用户提供高保真度的音视频保护功能

随着语音伪造技术的发展，AI 欺诈以及舆论引导事件层出不穷。为解决这一问题，我们开发了 **UnVoiceClone: 面向生成式伪造语音欺骗的鲁棒主动防御系统**。本系统防御后的语音经受克隆攻击，无法生成原始说话人声音，从而阻止说话人声音被恶意利用。同时，本系统关注人耳听感的提升，经过本系统处理的防御语音听起来与用户真实的声音保持高度一致。

(2) 具备良好的抗压缩性能，适用于主流社交媒体

为了减少网络通信的流量，社交媒体平台通常采用压缩编码的方式传播语音，导致信息的丢失，损害现有的防御措施。而本系统的防御语音在经过社交平台的压缩后，仍无法被利用生成原始声音。我们团队在**抖音、快手、小红书、B 站**等常见社交平台上进行了本作品的防御性能测试。经测试，我们的防御语音上传至相关平台后，面对克隆攻击仍表现出色，**所有防御语音均保持了稳定的防御性能**。

(3) 具有良好的泛化能力，可以防御其他未参与训练的语音伪造黑盒系统

现有的防御技术多针对特定模型进行训练，因此泛化能力有限。而我们的系统在面对真实应用场景中的语音克隆模型不可知的问题，对未知克隆模型仍具有良好的抗克隆能力。

在数字化时代的背景下，我们团队开发的 UnVoiceClone 系统因其出色的防御性能展现出广泛的应用潜力。本作品具有鲁棒性强、泛化性强、抗克隆能力强、防御语音保真度高的特点。这些特点使其不仅能有效遏制虚假语音的生成、保护个人声纹隐私，还能抵御当前盛行的 AI 欺诈和舆论引导等恶性事件，维护真实可信的网络环境。

关键字： 多媒体安全，对抗样本，主动防御，鲁棒扰动，动态集成

第一章 作品概述

1.1 选题背景

作为人类交流和人机交互的主要通信信息，语音不仅传递了需要表达的语言内容，也包含了说话人所独有的身份特征。深度神经网络和生成式人工智能技术的飞速进展，刺激了逼真语音克隆的发展（图1.1）。



图 1.1 发展迅速的语音克隆技术

而社交媒体语音的广泛传播（图1.2），为深度伪造提供了数据来源，这带来了严重的威胁，包括舆论引导、地缘政治紧张、金融市场混乱、诈骗、诽谤和身份盗窃等。此外，深度语音伪造的快速发展也对智能设备安全带来了新的挑战，合成的声音可以恶意地接管设备的控制，使支持语音认证的设备处于危险之中。




图 1.2 用户在公共平台上传自身语音数据

23 年 4 月，犯罪分子通过 AI 换脸和拟声技术，伪装郭某好友对其实施诈骗，诈骗金额高达 430 万^[1]；24 年 1 月，香港警方披露了一起 AI “多人换脸” 诈骗案，涉案金额高达 2 亿港元，警方调查得知，这起案件所谓的视频会议中只有受害人一个人是“真人”，其他“参会人员”都是利用 Deepfake 技术后的诈骗人员^[2]；24 年 1 月，美国新罕布什尔州的一些选民称接到了“拜登总统”的自动留言电话，告诉接听者不要在该州初选中投票，此举严重干预了选举的公正性，后经调查证实该电话是使用了深度伪造合成的虚假声音，迅速引起各方的警觉^[3]；24 年 2 月，陕西西安财务人员张女士接到“老板”视频通话要求转账 186 万元到指定账号，视频通话中人脸和声音的高度相似性导致张女士并未多加怀疑，致使 186 万元高额财款流失^[4]；24 年 4 月 23 号，全国首例 AI 生成声音人格权侵权案，在北京互联网法院一审开庭宣判，该案中被告方使用原告声音、开发涉案 AI 文本转语音产品未获得合法授权，判定构成侵权，违反了我国民法典第 1023 条^[5]。



图 1.3 人工智能伪造音视频相关新闻

针对深度伪造技术的恶意使用，全球各国都给予了极大的关注，颁布了一系列相关的法律法规。2016 年 4 月 14 日，欧洲议会投票通过了《一般数据保护法案》，取代现有的《数据保护指示》；2021 年 1 月 1 日起我国正式施行的《民法典》中的人格权编，明确规定了不得用技术手段伪造等方式侵害自然人声音，矛头直接指向 AI 欺骗；2022 年 6 月 3 日，美国参议院和众议院发布了《美国数据隐私和保护法》的草案；2022 年 6 月，欧盟更新了《虚假信息行为准则》；2023 年 1 月，我国颁布《互联网信息服务深度合成管理规定》；2023 年 7 月，我国颁布《生成式人工智能服务管理暂行办法》；2024 年 1 月，欧盟完成了《人工智能法》的定稿。

表 1.1 针对深度伪造技术恶意使用的法律法规简要内容

法律法规名称	颁布日期	主要内容
《一般数据保护法案》(GDPR)	2016 年 4 月	强化个人数据保护，限制使用个人数据制作深度伪造内容。
《中华人民共和国民法典》人格权编	2021 年 1 月	明确禁止利用技术手段伪造他人肖像、声音侵犯人格权。
《美国数据隐私和保护法》草案	2022 年 6 月	强调数据最小化原则，防止个人数据被用于制作深度伪造内容。
《虚假信息行为准则》更新	2022 年 6 月	加强对虚假信息的监管，包括深度伪造内容的共享机制和透明度要求。
《互联网信息服务深度合成管理规定》	2023 年 1 月	规范深度合成服务，包括真实身份认证和内容管理要求，防止深度伪造。
《生成式人工智能服务管理暂行办法》	2023 年 7 月	规定生成式人工智能服务管理要求，包括数据和技术管理规范。
《人工智能法》(EU AI Act)	2024 年 1 月	欧盟立法，规定人工智能的风险分级和监管要求。

现有的伪造语音具有高相似、难分辨、易合成的特点，极易被不法分子用作诈骗手段（图1.4）。目前，已有多项研究针对人类识别 DeepFake 合成音视频的能力进行了详细评估，Terblanche 等人^[6]测试了人们对伪造语音的识别能力，发现他们在真实信道下只有 56% 的正确率。Lewis 等人^[7]测试了人们对伪造视频的识别能力，发现当受访者被告知五个视频中至少有一个是深度伪造时，只有 21.6% 的人正确识别出伪造视频。在在线交互场景中，为实现快速网络传输，音视频数据通常需要压缩编码，这不可避免地会导致部分信息的丢失，进而增加了识别伪造内容的难度，也对现有伪造音视频检测算法的鲁棒性提出了新的挑战。鉴于现有的语音伪造检测方法存在诸多不足，我们团队决定将重心转向主动防御而非被动检测。基于实际应用场景，我们团队开发了高效且鲁棒的伪造主动防御系统 UnVoiceClone（简称 UnVC），适用于在线交互环境。不仅填补了现有技术的空白，还具有重要的研究意义和广泛的应用前景。




图 1.4 AI 语音诈骗日益猖獗

1.2 相关工作

针对整体作品的设计目标，我们团队对现有语音克隆伪造，说话人编码器和语音克隆防御技术进行广泛调研，相关工作总结如下。

1.2.1 语音克隆伪造

语音伪造的目的是生成目标说话人的声音，以欺骗人类听觉系统 (HAS) 或自动说话人验证系统 (ASV)。语音伪造在细微层面修改时域、频域的特征，使其更接近真实人说话时得到的特征，而达到攻击的效果。目前的语音伪造技术主要包括语音模仿 (Impersonation Attack)、语音合成 (Text to Speech, TTS)、语音转换 (Voice Conversion, VC) 和重放攻击 (Replay Attack, RA)。

模仿攻击是指通过人类模拟产生目标说话人风格的语音，属于非自动化的语音伪造手段，其实施难度较高，可模仿的目标说话人范围受限，抗检测能力弱。重放攻击是指对目标说话人的语音通过设备录制后，进行编辑和回放以产生高度逼真的目标说话人语音。这两个攻击的实施效果较差，且人为可操作性较弱。所以这里我们主要关注语音合成以及语音转换攻击。

语音合成：随着深度学习技术的发展，近年来的语音合成技术基本采用深度学习方法，主要包括管道式 (Pipeline) 语音合成和端到端式语音合成两类。管道式语音合成整体上可分为文本分析、声学模型、声码器三个模块，如百度人工智能实验室提出的 Deep Voice 系统^[8]，及改进后的基于注意力机制的全卷积语音合成系统 Deep Voice3^[9]；端到端式语音合成系统实现了直接输入文本或者注音字符，输出语音波形，极大程度地降低了语音合成系统构建的复杂度，减少了合成过程中的人工干预和对语言学相关背景知识的需求，取得了语音合成性能上的大幅提升。目前基于深度学习的端到端式语音合成系统可分为自回归模型和非自回归模型两类。

自回归语音合成基于序列到序列的生成模型，可以达到目前最优的语音合成效果，但是合成速度较慢，包括 WaveNet^[10]、Tacotron^[11] 或基于 GAN 的架构，如 HiFi-GAN^[12]。非自回归语音合成基于全并行网络结构，通过一次前馈计算生成整句语音，极大地提升了语音合成的速度，可控性强且语音合成质量接近自回归模型的效果，包括 FastSpeech^[13]，Parallel Tacotron^[14]，FastPitch^[15]，VALL-E^[16]，Yang 等人改进的 MelGAN^[17] 以及采用 VAE 架构的 VITS^[18]，Natural Speech^[19]。




图 1.5 语音合成发展进程

语音转换：随着近年来深度学习技术的广泛应用，语音转换的效果得到了显著提高。基于循环神经网络（RNN）和卷积神经网络（CNN）的模型，尤其是长短期记忆网络（LSTM）和生成对抗网络（GAN），在捕捉语音的时序特征和非线性变换方面表现出色。此外，基于注意力机制的变分自编码器（VAE）和端到端的 Transformer 模型进一步提高了转换的灵活性和质量。我们团队做了如下调研：

表 1.2 语音转换技术调研

	工作	架构
基于 GAN 的模型	StarGAN-VC[20]	使用星形生成式对抗网络 (StarGAN) 实现非平行数据的多对多语音转换，提高了语音转换的灵活性和实用性
	CycleGAN-VC3[21]	通过对抗训练、循环一致性损失、恒定 Q 变换、多尺度判别器等技术，实现了高质量的无监督语音转换
	MaskCycleGAN-VC[22]	基于 CycleGAN 的改进模型，引入了掩码机制 (Mask Mechanism) 以增强转换效果
基于自编码器的模型	AutoVC[23]	基于自编码器的语音转换模型，通过瓶颈层 (Bottleneck Layer) 学习语音的低维表示
	AdaIN-VC[24]	基于自适应实例归一化 (Adaptive Instance Normalization, AdaIN) 的语音转换模型
基于对比学习的模型	VQMIVC[25]	基于矢量量化变分自编码器 (Vector Quantized Variational Autoencoder, VQ-VAE) 和互信息 (Mutual Information) 优化的语音转换模型
基于扩散模型的模型	Diff-HierVC[26]	基于层次化扩散模型的语音转换方法，通过扩散过程逐步添加噪声并通过逆过程去噪实现转换




图 1.6 语音转换发展进程

综上所述，我们发现，语音合成和转换技术具有逼真、灵活和高效的特点，能够生成几乎无法与真实语音区分的语音，这对说话人识别系统和人耳带来了极大的威胁。随着语音克隆的创新不断，伪造语音检测的泛化性面临严峻挑战，使得检测算法变得更加被动和困难。因此，必须发展主动防御机制，增强系统的安全性和可靠性。

1.2.2 说话人编码器

说话人编码器（Speaker Encoder）是一种用于从语音信号中提取说话人特征的技术。它在语音处理领域，如语音合成（Text-to-Speech, TTS）和语音转换（Voice Conversion, VC）中发挥着重要作用。现有的说话人编码器主要可以分为以下几类，每类编码器有其独特的架构：

表 1.3 现有说话人编码器

	说话人编码器	架构
基于传统统计方法的编码器	i-vector	GMM-UBM + 因子分析
	Ivector-PLDA	i-vector + PLDA
	d-vector	DNN
基于深度神经网络的编码器	x-vector	TDNN + 统计池化层
	Xvector-PLDA	x-vector + PLDA
	ECAPA-TDNN	SE-Res2Block + TDNN
基于变分自编码器的编码器	VAE	编码器 + 解码器 + 潜在变量层
	VQ-VAE	VAE+ 向量量化
	AdaIN	VAE
	CVAE	VAE + 条件输入
其他	GE2E	LSTM
	ResNet	ResNet

随着新技术的不断涌现,说话人编码器也进行着迭代更新。针对 JFA(联合因子分析)方法对说话人差异和信道差异分别建模导致信道因子中携带的部分说话人的信息损失,Dehak^[27]提出了全局差异空间模型 i-vector,将说话人差异和信道差异作为一个整体进行建模。之后,Bahmaninezhad 等人^[28]发现这样会导致了 i-vector 同时含有说话人和信道的信息,但我们只关心说话人信息,由此引入了 i-vector/PLDA。

受强大的特征提取能力和深度神经网络(DNNs)成功应用于语音识别的启发,Heigold 等人^[29]提出了一种基于 DNN 的说话人特征提取技术。d-vector 直接对说话人进行建模,使用最后隐藏层的累积输出激活作为新的说话者的特征表示。到了 2018 年,Snyder 等人^[30]提出了 x-vector,把每个语音片段通过模型后的输出用一种方式聚合起来,而不是像 d-vector 那样简单的取平均。

针对传统的 AE 无法生成新的样本的问题,引入了 VAE,它结合了自动编码器(Autoencoder)和变分推断的思想,通过学习输入数据的潜在表示,来生成新的数据样本。然而 VAE 是无监督训练的,为了能够生成指定的数据样本,Ramchandran 等人^[31]提出了 CVAE,将标签信息加到 VAE 中辅助生成样本,从而实现控制某个变量来实现生成某一类指定语音。

在深度神经网络中,随着网络深度的增加,模型的训练变得越来越困难,何凯明等人^[32]在 2015 年提出 ResNet (Residual Network,残差网络),在网络层之间增加了残差连接,使得每一层不仅学习输入的直接映射,还学习输入的残差。2017 年,谷歌^[33]提出一种基于深度学习方法的 GE2E 说话人编码器,通过端到端的训练方法和专门设计的 GE2E 损失函数,直接优化说话人嵌入表示,使得同一说话人的嵌入向量彼此接近,而不同说话人的嵌入向量彼此远离。

说话人编码器各式各样,不同模型使用不同的特征提取方法,致使主动防御技术的泛化性提升成为研究重点。我们团队关注于防御样本泛化性提升,致力于研究能够有效应对不同语音伪造方法的主动防御机制,从而增强系统的安全性和可靠性。

1.2.3 语音克隆防御

研究者通过研究语音克隆防御技术,抵御语音伪造带来的威胁,语音克隆防御技术主要分为被动防御技术和主动防御技术,被动防御技术是指伪造语音检测技术,主动防御技术是指通过添加对抗扰动预先破坏语音伪造模型的有效性,从而防止语音被恶意转换和伪造。

表 1.4 语音克隆防御技术的分类

	分类	特点
被动防御	基于特征检测	考虑语音信号、声纹特征和频谱分布等生物信息的差异特征
	基于数据检测	依靠大量的标记数据训练神经网络进行伪造语音的检测
主动防御	基于对抗样例的主动防御	通过添加对抗扰动预先破坏语音伪造模型的有效性，从而防止语音被恶意转换和伪造

被动防御：针对语音转换的被动防御主要分为基于特征检测和基于数据检测^[34]。基于特征的检测主要考虑语音信号、声纹特征和频谱分布等生物信息的差异特征，因为伪造语音在合成时更注重与真实语音听感相似，不会关注信号和特征上的相似性，在信号微观层面会具有生成方法的固有特征，相关工作有 CFCCIF^[35]，SiameseCN^[36]等。随着语音伪造技术的不断发展，基于传统知识的伪造语音的典型特征在伪造技术改进中改变或减少，原有基于特征的检测依靠提取几个简单的语音特征已不足以处理大量且复杂的数据。因此，更多的研究重点转向了基于数据的伪造检测，见表1.5。

表 1.5 基于数据的被动检测技术的分类

	方法	原理
卷积神经网络	轻量卷积神经网络 (LCNN) [37]	减少计算成本和存储空间的情况下处理大规模数据，其核心是最大特征图 (MFM) 激活函数
	残差网络 (ResNet) [38]	通过跳过连接解决深层网络的梯度消失问题，提高网络的学习能力
	Res2Net[39]	将特征分成多个通道组，进行多尺度变换，提高系统面对未知攻击的泛化能力
	挤压-激励网络 (SENet)[40]	通过挤压-激励操作建模通道间的相互依赖，提高模型专注于伪造检测相关通道信息的能力
循环神经网络	门控递归单元 (GRU) [41]	结合 LCNN 和 RNN，提取帧级别和上下文特征
其他架构	LC-GRNN [42]	结合 LCNN 和 GRU 的优势，增强检测系统的判别能力
	ResMax[43]	结合 LCNN 中的 MFM 激活函数和 ResNet 残差结构，减少参数量，提高检测效果
	非负矩阵分解的盲信源分离 (BSS) [44]	将合成语音分解成真实语音和伪影部分，再进行分类
	Spoofprint[45]	基于说话人水印模型的检测系统，分为注册和验证两阶段
	集成模型 [46]	建立了包含卷积神经网络、卷积循环网络、Wave-U Net、支持向量机以及高斯混合模型的集成模型

主动防御：

主动防御方法通过添加对抗扰动预先破坏语音伪造模型的有效性，从而防止语音被恶意转换和伪造^[47, 48]。在语音领域，Huang 等人^[49]对语音转换模型进行了初步探索，在要被保护的说话人所发出的话语中加入人类难以察觉的干扰，提出了端到端攻击、嵌入攻击和反馈攻击三种不同的方法，使被转换话语的说话人特征与被防御的说话人有很大的不同，原理如图1.7。但迁移性较差。为了解决这些不足，AntiFake^[50]通过在循环机制引入一个人来自动调整优化过程，达到了在语音质量和保护强度之间的平衡，AntiFake 采取了一种积极主动的方法，以防止使用隐蔽的对抗性扰动进行未经授权的语音合成，其核心思想是通过在条件性语音合成中使用说话人身份控制的说话人嵌入来干扰合成过程。




图 1.7 Defend Your Voice 原理图

被动防御的伪造检测性能虽然在不断提升，但当前伪造语音检测技术对不同编码压缩和具备环境噪声的语音缺乏检测鲁棒性，对不同方式生成的伪造语音缺乏防御通用性，方法相对被动且可解释性不足；主动防御技术改善了事后防御的被动局面，但当前主动防御技术的鲁棒性、防御后语音的保真度、防御技术的泛化性、伪造与真实语音可区分性还有待提升，成为主动防御技术的研究重点和难点。

1.3 特色描述

针对当前主动防御技术面临的防御语音抗克隆能力弱、防御语音保真度低、鲁棒性弱、泛化性差的难题，我们开发了 UnVoiceClone：面向生成式伪造语音欺骗的鲁棒主动防御系统系统，经过本系统处理后的防御语音即使经受克隆攻击，也无法生成原始说话人声音，从而阻止说话人声音被恶意利用（图1.8）。

本作品具有适用范围广、防御语音抗克隆能力强、防御语音保真度高、鲁棒性高、泛化性强、高效性的特点。首先，本作品引入基于 CNN 的 inaSpeechSegmenter 来精准定位语音说话人信息并采用多线程并行技术，使系统算法运行效率提升 20%。其次，本作品在舆论引导、AI 欺诈、声音版权保护领域都能够发挥重要作用，为构建良好的



图 1.8 UnVoiceClone 系统功能

网络环境提供了坚实的保障；同时，本作品还能够应对现有的各种可能的攻击手段，例如语音转换、语音合成、声纹伪造等，无论攻击者采用何种技术手段，本作品的解决方案都能够抵御潜在的攻击风险，确保语音的安全性。

其主要特色如下：

(1) 通过异性身份替换的声纹隐私主动防御技术提升防御语音的抗克隆能力

针对现有防御技术中，防御后的语音经过伪造生成得到的语音和原始语音相似度过高导致人耳和机器难以判别，及与第三方说话人声音类似造成第三方声纹信息泄露的问题，本作品关注防御语音的抗克隆能力（以防御语音克隆后与真实语音的“差异性”来度量）提升，提出了**基于 KL 散度的声纹特征选择算法**，并结合了**异性身份特征替换与基音可控调节**。通过选择与原始语音所在的 KL 散度聚类中心差异最显著的前三个说话人性别不同的聚类中心并对基音进行可控调节，增加原始声纹与伪造声纹之间的区分度，之后，通过使用加权平均的手段增强了合成声纹的唯一性，显著降低防御后的语音经过语音克隆得到的语音与第三方真实人接近的可能，在保护第三方未知说话人隐私的同时，最大限度地增加防御后克隆语音与真实语音的差距，使得人耳分辨更加容易。为了验证本作品性能，我们采访了 80 人，对本作品防御后克隆语音和原始受害者语音之间的身份差异（即感知说话人不相似 PSD 指标）进行了辨别，测试数据表明，本作品的 PSD 值在黑盒模型下平均为 **3.71**，较 emb attack 和 AntiFake 方法分别增加了 **2.32**，**1.76**。

(2) 基于高斯分布逼近损失和软约束损失提升防御语音的保真度

针对现有技术中防御语音存在较大背景噪声导致人耳听感下降的问题，本作品采用了**高斯分布逼近损失和软约束损失**。通过高斯分布逼近损失，使防御语音严格遵守高斯分布规律，确保防御语音在特征层面精准地模拟目标语音，这不仅保证了鲁棒性，也提高了防御语音的保真度，并通过软约束损失确保生成的语音在波形上不会与原始语音有过大的偏离，进一步提升了防御语音的保真度，确保经过本系统处理的防御语音听起来与用户真实的声音保持高度一致。为了验证，我们令包括 8 组男生和 8 组女生在内的 16 组志愿者（每组 5 人）对本作品生成的防御语音进行语音自然度的判别，结果显示本作品提出的 UnVoiceClone 方法较 AntiFake 方法 MOS 值（人耳语音自然度）有了一定的提升；同时，ASV（语音说话人相似度）较 emb attack 和 AntiFake 方法分别提升了平均 **1.92%** 及 **10.68%**。

(3) 采用高斯噪声优化的 WaveGlow 对抗语音生成方法提升防御能力的鲁棒性

针对现有防御在经历现实应用场景下一些常见的操作（如加噪，裁剪，压缩以及重采样等）后，会造成防御失效的问题，本作品关注于防御效果的鲁棒性提升，提出了**高斯噪声优化的 WaveGlow 对抗语音生成方法**。不同于以往技术直接在原始语音波形中添加噪声生成对抗语音，我们的方法通过确保模型输出接近标准高斯分布，保证对抗扰动部分与防御语音属于同一分布，从而增强了模型对压缩变化的不敏感性，提高了防御能力的鲁棒性，使得本系统处理的防御语音在经过社交平台的压缩后，仍无法被利用生成原始声音，保持良好的防御能力。测试数据表明，本作品的方法在经过重采样，剪裁，加噪，AAC 压缩，MP3 压缩等常见语音处理操作后，防御成功率平均为 **60.04%**，较 emb attack 和 AntiFake 方法分别增加了 **22.75%** 和 **18.14%**。

(4) 利用动态权重调整的集成说话人编码器策略与梯度正则提升防御能力泛化性

针对现有大多数主动防御通过对特定模型进行针对性训练导致的防御能力泛化性较低的问题，本作品提出了一种**动态权重调整的集成说话人编码器策略**，并在 Adam 优化器基础上融入**梯度正则化和锐度感知最小化 (SAM) 技术**。本作品利用动态权重调整策略优化各个模型对整体攻击策略的贡献，通过对每个说话人编码器损失函数的历史统计数据（均值与标准差）进行归一化处理，从而有效地消除由于各模型损失函数尺度和范围的内在差异所带来的影响。同时，在 Adam 优化器的基础上，融合梯度正则化和锐度感知最小化 (SAM) 技术指导高斯噪声的优化，显著提高模型对不同攻击情景的适应性，使得我们的系统在面对真实应用场景中的语音克隆模型不可知的问题，对未知克隆模型仍具有良好的抗克隆能力。测试数据表明，本作品的方法在未知黑盒模型（将 LVC-VC、VALL-E、XTTS2、ElevenLabs 作为黑盒测试模型）场景下，防

御成功率平均为 **66.29%**，较 emb attack 和 AntiFake 方法分别增加了 **20.69%**，**13.2%**。

1.4 应用前景分析

在数字化时代背景下，我们团队所开发的 UnVoiceClone：面向生成式伪造语音欺骗的鲁棒主动防御系统，不仅是语音数据保护的创新解决方案，更是一个针对语音隐私侵犯和安全威胁的强大防线。此技术不单单有效遏制语音的不当转换与恶意利用，还极大地加强了个人隐私及安全防护的多层次体系。本作品可用于以下实际应用场景：

政治重要人物的声纹隐私保护：在当今信息化时代，政治重要人物的言论和指令具有极高的敏感性和重要性。然而，随着语音克隆技术的不断进步，声纹隐私保护面临着前所未有的挑战。不法分子可能通过伪造或篡改语音内容，对政治重要人物进行恶意攻击或造假，从而通过舆论引导危害国际政治局势。应用本作品的技术，可以对这些重要人物的语音数据进行防御处理，即使被恶意第三方获取，也无法生成具有原始说话人音色的语音，从而有效防止身份冒用、伪造指令等恶意行为，确保政治重要人物的声纹隐私得到充分保护，保障其言论和指令的安全性与真实性。

AI 欺诈事件的有效遏制：随着语音克隆技术的不断发展，AI 欺诈事件层出不穷。在金融领域，欺诈者利用 AI 技术进行电信诈骗、信用卡盗刷、身份盗窃等金融欺诈活动；在说话人验证系统中，不法分子利用 AI 生成的声音伪造授权用户的声纹，进而获取未经授权的访问权限；在医疗系统中，恶意攻击者通过伪造语音指令来篡改设备设置或者进行恶意操作，从而威胁患者的生命安全等。我们的系统通过在语音数据中添加对抗扰动，使得经过本系统处理后的防御语音即使经受克隆攻击，也无法生成原始说话人声音，从而阻止说话人声音被恶意利用，有效遏制 AI 欺诈事件的发生，确保金融交易、身份验证、医疗系统等领域的安全性和可靠性。

娱乐和媒体行业的声音版权保护：在娱乐和媒体行业，声音版权的保护变得越来越重要。艺人和公众人物的声音容易被伪造，用于传播虚假信息或进行非法活动。通过应用本作品的主动防御技术，在语音中添加对抗扰动，可以有效防止语音伪造行为，使得伪造声音在生成时质量显著下降，保护声音版权，确保艺人和公众人物的声音不被恶意使用，维护其声誉和合法权益。

综上所述，本作品不仅**保护了个人和企业的声纹隐私数据安全**，还能够有效遏制**AI 欺诈、舆论引导和声音侵权事件**的发生，减少敏感数据的非法利用。确保信息系统的可信度、可靠性和可用性，为构建良好的网络环境提供了坚实的保障。因此，本作品在**内容安全领域中的隐私保护**方面具有极其广阔的应用前景和重要的战略意义。

第二章 作品设计与实现

本作品主要目标是设计一套基于对抗攻击的语音伪造主动防御技术方案，并基于 Web 框架搭建一套用户操作和交互良好的系统界面。**系统设计旨在为用户提供语音防御功能**。用户上传需要防御的音视频，系统将对其中的说话人语音信息部分进行防御处理，生成防御后的音视频。

经过防御后的语音应用于语音克隆模型将伪造失败，即无法利用该语音中说话人的音色合成冒充该说话人的伪造语音，**而是生成不属于该说话人的音色**。这一功能有效防止恶意第三方攻击者滥用克隆语音，防止舆论操控、金融诈骗等不法行为的发生，从而实现声纹隐私信息的安全保护效果。

基于此目标，我们团队在系统设计中综合考量了抗克隆能力、语音保真度、鲁棒性和泛化性等关键性能指标。核心技术包括采用高斯噪声优化的 WaveGlow 对抗语音生成方法和动态权重调整的集成说话人编码器策略，共同构成了 UnVoiceClone：面向生成式伪造语音欺骗的鲁棒主动防御系统。本章将详细介绍系统的主要功能、用户界面、总体架构、工作流程以及这些关键技术的原理。通过这种方法，系统旨在有效防御语音伪造攻击，同时确保防御过程中不损害语音的自然度和清晰度，致力于提供良好的用户体验。

2.1 系统功能与界面

本作品设计的呈现形式为基于 B/S 架构设计的 Web 网页应用系统。系统通过用户输入需要防御的音视频，经过对音视频数据进行处理后，输出经过主动防御的音视频。经过防御后的音视频无法应用于大多数语音克隆模型，无法利用该语音中说话人的音色合成冒充该说话人的伪造语音。UnVoiceClone 系统生成的防御后音视频能应用于主流社交平台，如下图 2.1，我们将介绍本项目作品的系统功能与界面。




图 2.1 UnVoiceClone web 应用示意图

2.1.1 系统主页



图 2.2 系统主页

需要对于语音进行防御操作的用户，登录 UnVoiceClone 应用系统平台，即可实现对语音文件的 UnVoiceClone 防御操作。本作品应用系统的主页如图 2.2所示。

如图 2.3所示，本作品为用户提供了几大主要功能，分别是“音频防御”、“视频防御”和“音视频防御测试”。用户可以根据自身需求，自行选择并点击相应功能，进入对应的功能界面。



图 2.3 功能展示

2.1.2 音频防御功能

对于带有说话人语音信息的音频，只需要用户在主页的功能展示中选择“音频防御”，即可进入相应的功能界面，完成添加 UnVoiceClone 防御的操作，如图 2.4所示。



图 2.4 音频防御功能界面

根据页面提示信息，用户需上传包含说话人语音信息的音频文件。在上传区完成上传工作后，系统会显示上传音频的波形图，用户可在此播放原始音频。用户需要点击“UnVC 防御”按钮启动防御转换功能并等待防御操作的完成，生成防御后的语音波形图并在下载区显示。用户同样可以在下载区播放防御转换效果。最后，用户通过点击“下载音频”按钮，将防御后的可应用的 UnVoiceClone 防御音频保存至本地。

2.1.3 视频防御功能

本作品在音频防御功能的基础上，新增了对视频格式的防御支持。其核心是对视频中的说话人语音部分进行防御处理。具体而言，通过对视频中的音频部分进行提取和分析，对说话人语音部分实施防御操作，最终重新合成并输出经过 UnVoiceClone 防御处理的视频，如图 2.5 所示。




图 2.5 视频防御功能界面

根据页面提示信息，用户需上传需防御的视频文件。在上传区完成上传操作后，

会显示视频中音频部分的波形图，用户可以在此播放原始视频。用户需要点击“UnVC 防御”按钮启动防御转换功能并等待防御操作完成，生成的防御后视频在下载区中展示。用户同样可以在下载区播放防御转换效果。最后，用户点击“下载视频”按钮，将防御后的可应用的 UnVoiceClone 防御后视频保存至本地。

2.1.4 音视频防御测试功能

在音频防御和视频防御功能模块中，本作品已基本实现核心功能，能够通过上传文件和点击按钮的形式快速生成防御后的音频或视频。

为了增强用户体验，帮助用户更好地了解和应用本系统，本作品特别设置音视频防御测试功能模块。该模块包括音频转换测试和音频合成测试两个分支功能，用户可在此处测试并体验防御后音频的转换效果是否符合预期。测试功能板块支持音频和视频文件格式，以满足更广泛用户的实际需求。

对于音频转换测试功能，用户需上传一段原始音频作为被转换的音频。在“目标音色音频”中上传希望转换成的目标音色音频，用户可以上传经过 UnVoiceClone 防御后的音频或视频，方便测试 UnVoiceClone 防御效果。系统将通过实际应用的音频转换功能生成转换后的音频。用户可以通过下载或现场播放的形式，收听并体验 UnVoiceClone 防御后的音频转换效果与目标音色的差异，功能界面如图 2.6 所示。




图 2.6 音频转换测试功能界面

对于音频合成测试功能，设计思路与音频转换测试功能相似，用户需要上传一段待转换成音频的文本。在“目标音色音频”部分上传希望转换成的目标音色音频，用户可以上传经过 UnVoiceClone 防御后的音频或视频，方便测试 UnVoiceClone 防御效果。系统将通过实际应用的音频合成功能生成转换后的音频。用户可以通过下载或现场播放的方式，收听并体验 UnVoiceClone 防御后的音频转换效果与目标音色的差异，

功能界面如图 2.7所示。

防御测试功能板块的实现，能够帮助用户更好地了解和体验系统的性能效果，并确认防御效果是否符合预期，发挥关键作用。




图 2.7 音频合成测试功能界面

2.2 系统工作流程




图 2.8 UnVoiceClone 系统架构图

本系统整体架构由用户操作端、后台处理端、结果输出端组成。系统架构图见图 2.8所示，涵盖了从用户操作端到结果输出端的整个流程。本作品旨在提供全面有效的语音伪造主动防御系统。

2.2.1 用户操作端

用户操作端是系统的前端入口，用户通过此端口将带有说话人语音信息的音频或视频数据输入系统。该模块的设计简洁直观，用户可以轻松进行以下操作：

① **音频输入**：用户可以通过录制或上传音频数据，系统将使用 Flask 构建的接口捕捉这些数据并传输至后台处理端。Flask 允许系统以最小的延迟处理用户的实时或预录制音频，确保数据的快速和安全传输。

② **视频输入**：用户可以通过录制或上传视频数据。系统利用 Flask 接口接收和处理这些视频文件。这一过程借助于 Flask 的高效数据处理能力，确保视频文件的快速处理而不影响其播放质量。

用户操作端旨在简化用户的操作流程，确保数据能够快速且准确地输入到系统中，为后续的处理和防御环节奠定坚实基础。除了基础的音频输入功能外，本系统还引入了视频输入功能，并在后续的功能模块中，从视频中提取同步音频。这一增强功能使得本作品能够在移动媒体平台上针对视频中的说话人进行实时的语音伪造主动防御。这一改进不仅提升了系统的应用性和灵活性，更是显著扩展了系统的适用范围。

用户操作端通过提供音频提取以及音视频同步处理的全面功能，不仅提高了系统的操作便捷性，还实现了移动媒体的全范围保护，使得我们的系统能够适应更广泛的使用需求和各种动态环境。

2.2.2 后台处理端

后台处理端是系统的核心组成部分，主要负责从用户操作端接收的音频与视频数据进行全面的采集、处理，并实施针对语音伪造的主动防御措施。该模块由多个专业子系统组成，每个子系统都针对特定的语音伪造防御需求进行定制化处理，确保整体防御策略的鲁棒性、泛化性，防御后语音保真度、伪造与真实语音的可区分性。主要子系统包括：

① 数据采集模块：

音频数据采集：负责接收用户输入的音频数据，进行标准化的预处理操作，以便后续的防御操作。

视频数据采集：负责接收用户输入的视频数据，系统使用基于卷积神经网络的 `inaSpeechSegmenter` 模型提取其中的音频信号。该模型高效地区分音频中的语音、音乐及噪声部分，并在识别到的语音区域中进一步通过性别标记，区分男声或女声。通过这种方式，系统可以准确地忽略背景噪声和无关音频部分，仅对有意义的音频信号进行处理和性别判定。

② 声纹隐私防御模块：

异性身份特征替换：此模块采用 KL 散度聚类方法对系统中存储的语音库进行高效的声纹分析和聚类。通过计算不同声纹间的 KL 散度，有效地区分并聚类声纹特征，从而确保每个类别的声纹具有独特性和代表性。进一步地，系统从聚类结果中随机选择三个类别，计算这三个类别声纹特征的均值，形成一个新的声纹特征。这一新特征既属于异性，又不存在于实际的用户数据中，从而确保原始声纹不会被识别或追踪，增强用户隐私保护的效果。这种方法不仅提高了声纹替换的安全性，还保证了操作的随机性和不可预测性。

基音可控调节：本模块采用 Pitch Smoothing（基音平滑）和 Pitch Shift（基音移动）方法对语音的基音部分进行可控调节，以进一步增强防御效果。通过 Pitch Smoothing 平滑处理基音频率的变化，使声音更加自然，同时削弱原始声纹的特征。Pitch Shift 则通过调整音频的基音频率，改变声音的高度，从而扰乱和混淆声纹特征。这些技术共同作用，使得攻击者难以恢复原始声纹特征，进一步增强语音伪造主动防御效果。

③ UnVoiceClone 防御模块：

高斯分布约束：通过利用高斯分布对语音特征进行约束，调整语音数据的分布，使其符合高斯分布。此过程确保语音在经过移动平台或攻击者常用的预处理方式处理后，仍保留足够的对抗特性。通过以高斯分布为中心点，平衡真实语音与伪装语音特征，从而提高语音数据的隐私保护水平和对抗鲁棒性。

说话人编码器动态集成攻击：系统集成多种说话人编码器（Speaker Encoder），并采用动态调整策略。根据生成的对抗语音攻击效果，实时进行梯度调整，以提升对抗语音对各类黑盒语音伪造模型的泛化性。通过这种方式，即使在未知模型结构的情况下，UnVoiceClone 方法仍能提供较强的语音伪造防御效果。这样，可以确保系统在不可知的被攻击场景下都能有效保护用户的语音隐私。

④ 对抗音频生成模块：

对抗语音生成：利用前述防御模块提供的训练策略，训练生成用户输入语音数据经 UnVoiceClone 方法保护后的对抗语音。该生成的对抗语音具有高度的对抗性，能够有效保护原说话人的语音免遭伪造和滥用。

后台处理端通过采取上述多层次的处理和防御措施，有效地将 UnVoiceClone 方法整合应用于用户输入的音频和视频数据。这确保了当用户的音频数据在移动媒体中传输时，用户的音视频信息获得全面且有效的隐私保护。

2.2.3 结果输出端

结果输出端致力于为用户提供经过严格 UnVoiceClone 方法处理的音频和视频数据。在语音伪造主动防御的基础上，本作品确保了音频和视频数据的高保真度和良好的同步性，从而不影响用户体验。

输出端还包括一个直观的可视化界面，使用户能够清楚地看到保护前后的音频和视频数据效果，直观评估隐私保护的成效。用户还可以选择导出受保护的音视频数据，以便后续分享或存档，进一步确保数据的隐私性和安全性。

界面设计友好、操作简便，用户可以轻松管理和使用处理后的数据。用户可以选择多种格式导出受保护的语音和视频数据，以便后续分享或存档。这些格式包括常见的语音格式（如 MP3、WAV）和视频格式（如 MP4、AVI），确保我们的系统在多种移动平台上的兼容性和使用便捷性。

2.3 关键技术原理与实现

2.3.1 算法总体概述




图 2.9 UnVoiceClone 算法总体框架

为了应对现有主动防御技术面对社交媒体中常见的压缩和重采样预处理后防御鲁棒性不足、在未知说话人编码器的伪造攻击场景下泛化性较弱、以及很难保持语音保真度和区分性的问题，我们设计下列方法予以应对：首先，通过基于 KL 散度聚类来选择“伪装说话人”，我们显著增强了克隆后语音与真实语音的差异性，从而提升了**抗克隆能力**。其次，我们采用了高斯噪声优化的 WaveGlow 对抗语音生成技术，这

不仅确保了在防御机制激活时不损害**语音保真度**，而且强化了语音在经历社交媒体压缩后的抗克隆性能，保证了技术的实际应用场景中的**鲁棒性**。最后，通过开发动态权重调整的集成说话人编码器策略，我们确保了系统面对未知克隆算法时的高效表现，增强了防御技术的**泛化性**。最终，本作品提出了完整的 **UnVoiceClone-面向生成式伪造语音欺骗的鲁棒主动防御技术**。图 2.9展示了我们团队提出的 UnVoiceClone 算法总体框架。

2.3.2 基于匿名异性身份替换的声纹隐私主动防御

声纹隐私防御在语音伪造主动防御领域中扮演着至关重要的角色。其核心目标是通过精密的防御机制，确保经过语音合成或语音转换的语音伪造攻击之后生成的语音与原始语音在音色特性上存在显著差异。这种差异不仅能够通过自动化的机器分析方法检测出来，还能够让人工听识者明显感知到变化。通过这种方式，能有效阻止攻击者利用伪造的声音进行欺诈或误导，从而为用户的声纹数据提供强大的安全保护。

当前的语音伪造主动防御策略大多集中于保护原始说话人的声音特征，以防止恶意篡改或模仿。然而，这些方法存在一个显著的潜在问题：在尽力使伪造语音的声音特性与原始声音差异化的过程中，可能无意中使得这些声音特性接近于一个真实存在但未知的第三方说话人的声音。这种情况的发生主要是由于深度学习模型在本质上对数据进行高度抽象和转换处理的特性所致。

深度学习模型通过从大量数据中学习得到抽象特征，旨在捕捉输入数据中的关键信息。然而，当模型应用于防御语音伪造时，它们的目标通常是最大化原始说话人声音与伪造声音之间的差异。在这一过程中，由于模型的泛化能力和处理深度，可能不经意地将处理后的声音特性推向其他实际存在的说话人的声音特性空间，尤其是在没有充分训练数据覆盖所有潜在说话人的情况下更为常见。




图 2.10 声纹隐私防御关键问题

这种现象揭示了一个重要的安全漏洞，即现有的声纹防御机制可能因为过度调整

而失去对说话人身份的精确控制，从而无意中造成新的隐私泄露风险。因此，设计语音伪造防御系统时，除了需要关注如何增加原始声音与伪造声音的区分度之外，还应当考虑这种调整可能导致的其他安全隐患，即确保声音特性的调整不会意外靠近其他真实说话人的声音特性。

为了解决现有声纹防御机制可能因为过度调整而失去对说话人身份的精确控制，从而无意中造成新的隐私泄露风险的问题，本作品引入了基于 KL 散度的声纹特征选择算法。基于此技术，我们团队进一步增强了主动防御效果，引入了基音可控调节技术。这些技术的实施旨在确保语音伪造产生的语音不仅在音色上与原始说话人有显著差异，还在音质、音调等基音特征上进行了有效的偏离。这样的技术组合增强了本作品声纹隐私防御方法的复杂性和有效性，具有较强的抗语音克隆能力。

(1) 基于 KL 散度的声纹特征选择算法：

在实施基于 KL 散度的声纹特征选择算法中，本作品首先采用 Softmax 函数将每个声纹特征向量转换成概率分布，以便在概率空间内进行特征比较。Softmax 函数定义如下：

$$P(x_i) = \frac{e^{x_i}}{\sum_j e^{x_j}} \quad (2.1)$$

其中给定声纹特征向量 $\mathbf{x} = [x_1, x_2, \dots, x_n]$ ， x_i 是声纹特征向量中的第 i 个元素。此转换将每个声纹特征向量有效地表达为概率分布，为后续的概率比较及差异度量提供基础。

接下来，本作品利用高斯混合模型（GMM）对所有说话人的声纹特征向量进行聚类。通过聚类，我们可以得到多个聚类中心，每个中心代表一个类别的典型声纹特征。这些聚类中心可以看作是目标概率分布 Q 的组成部分。

假设有 K 个聚类，每个聚类由一个高斯分布表示：

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x \mid \mu_k, \Sigma_k) \quad (2.2)$$

其中 π_k 是第 k 个高斯分布的混合系数， $\mathcal{N}(x \mid \mu_k, \Sigma_k)$ 表示均值为 μ_k 、协方差为 Σ_k 的高斯分布。

然后，使用期望最大化（EM）算法对声纹特征向量进行训练，得到 K 个聚类中心的参数 π_k, μ_k, Σ_k 。最后，聚类中心的均值向量 μ_k 代表每个类别的典型声纹特征，通过这些均值向量可以构建目标概率分布 Q ：

$$Q(y_i) = \frac{e^{\mu_i/T}}{\sum_j e^{\mu_j/T}} \quad (2.3)$$

其中, μ_i 是第 i 个聚类中心的均值向量。

一旦获得聚类中心后, 我们计算被保护的声纹样本的概率分布 P 与这些聚类中心的概率分布 Q 之间的 KL 散度。KL 散度作为衡量两个概率分布相对熵的指标, 其计算公式为:

$$D_{KL}(P \parallel Q) = \sum_i P(i) \log \frac{P(i)}{Q(i)} \quad (2.4)$$

其中 P 和 Q 分别代表不同的概率分布。在此算法中, P 代表选定被保护的声纹样本的概率分布, 而 Q 代表聚类中心的概率分布。通过计算每个声纹样本与聚类中心之间的 KL 散度, 可以量化它们之间的信息差异, 进而识别出与原始声纹差异最大的特征。

在基于 KL 散度的声纹特征选择算法的执行过程中, 一旦完成了声纹特征向量的概率分布转换和 KL 散度计算, 接下来的步骤是精确地挑选出具有最大差异性的特征, 以强化声纹的防御机制。这一过程分为两个关键步骤:

Step1: 选择差异最显著的特征。基于计算得到的 KL 散度, 我们识别出与原始语音所在的聚类中心差异最显著的前三个聚类中心。选择 KL 散度最大的聚类中心的原因在于, 这些特征在概率分布上与原始语音特征的差异性最为突出, 从而能够提供更强的防御能力。这种方法通过显著增加原始声纹与伪造声纹之间的区分度, 有效降低了声纹特征被模仿或误识别的风险。

此外, 我们特别选择与原始说话人性别不同的聚类中心。这一选择基于以下观点^[51]: 尽管不同模型在识别个体身份的说话者边界上可能存在显著差异, 但在表征性别的声学特征方面, 不同模型间具有更多相似性。因此, 在优化过程中, 当目标是不同性别的说话者时, 这些基本声学特征不可避免地发生改变, 从而导致较好的防御效果。从保护的角度来看, 这种现象对我们的 UnVoiceClone 方法非常有利。生成的伪造语音如果与原始说话人性别不同, 受害者就更容易辨别出伪造语音。人类在区分不同性别的说话者时具有更高的敏感度, 这进一步增强了 UnVoiceClone 的防御效果。

Step2: 计算最终的声纹特征向量。本作品采用了一种加权平均的方法, 该方法考虑了选定的前三个聚类中心的概率分布和它们的差异性。每个聚类中心的权重由其与原始声纹的 KL 散度大小决定, 从而确保具有更大差异的聚类中心在合成过程中具有更高的影响力, 如图 2.11 所示。




图 2.11 基于 KL 散度的声纹特征选择

设 P_1, P_2, P_3 分别为选定的三个聚类中心的概率分布，相应的权重 w_1, w_2, w_3 根据每个聚类中心与原始声纹的 KL 散度 $D_{KL,1}, D_{KL,2}, D_{KL,3}$ 计算得出，权重计算公式为：

$$w_i = \frac{D_{KL,i}}{\sum_{j=1}^3 D_{KL,j}} \quad (2.5)$$

这样，合成的声纹特征向量 $\bar{P}$ 通过下面的加权平均公式得到：

$$\bar{P} = w_1 P_1 + w_2 P_2 + w_3 P_3 \quad (2.6)$$

这个合成过程的设计旨在利用多个高差异性的特征来构建一个更为稳健和难以模仿的声纹特征向量。通过这种方式，每个聚类中心的贡献与其独特性成正比，进而增强了合成声纹的唯一性，并提升了整个系统的安全性。这种方法确保了在声纹调整过程中，合成的声纹特征不会无意中靠近其他实际存在的说话人的声音特性，而是来自于一个并不真实存在的说话人。从而有效避免了潜在的隐私泄露和安全风险。

(2) 基音可控调节：

在声纹识别系统中，基音（即声音的基本频率）和其他声学特征能够提供丰富的个人信息。因此，通过精确控制这些特征，本作品能够有效地保护个人隐私免受未经

授权的访问和滥用。基音可控调节的技术主要包括两种方法：*Pitch Smoothing*（基音平滑）和 *Pitch Shift*（基音移动）。

1) Pitch Smoothing（基音平滑）

基音平滑技术通过调整语音的基音轨迹使其更加平滑，减少基音的自然波动和个性化特征。这种技术通常用于合成单调的语音或消除不自然的语音震动，以增强语音隐私保护。具体地，基音平滑可通过下式表示：

$$f_{smooth}(t) = \alpha f(t) + (1 - \alpha)\bar{f} \quad (2.7)$$

其中， $f(t)$ 是原始语音在时间 t 的基音频率， $\bar{f}$ 是语音段内的平均基音频率，而 α 是平滑系数，控制平滑程度。通过适当调整 α ，可以有效地抑制声纹的个性化特征，同时减少基音的快速变化，混淆声纹分析系统。

2) Pitch Shift（基音移动）

基音移动技术通过改变语音信号的基频，使得语音听起来更高或更低。此方法可表示为：

$$f_{shifted}(t) = f(t) \cdot (1 + \beta) \quad (2.8)$$

其中， β 是基音移动系数，正值导致基音升高，负值导致基音降低。通过适当的调整 β ，基音移动可以使声纹难以被原始的声纹识别系统识别，从而保护说话者的声纹隐私。此技术应用在本作品声纹隐私防御部分中，它可以有效地改变声纹的核心特性，显著增加声纹识别的难度。




图 2.12 基音可控调节语音前后对比

通过这种技术的应用，可以大幅提升声纹数据的安全性，有效防止声纹信息的非法使用和泄露。

2.3.3 高斯扰动优化的 WaveGlow 对抗语音生成

在当前的语音伪造主动防御技术研究中，尽管某些方法在理论层面上表现出较强的防御能力，并能够在模拟语音伪造情境下达到预期效果，从而有效保护原始说话人的音色特性。然而，当这些方法应用于实际环境中时，其防御效果在面对常见的语音处理操作（如剪切和时间缩放）时却显得不尽如人意。

如表 2.1所示，网络媒体广泛使用的有损压缩技术，以及用于优化语音传输的重采样技术，对防御技术保护语音中的对抗语音的完整性和有效性提出了巨大挑战。这些压缩技术通过去除人耳不易察觉的声音信息来减少文件大小，从而严重破坏了对抗语音的特征。此外，重采样技术通过改变语音数据的频率成分，进一步干扰了对抗语音的结构和分布。这些因素共同作用导致当前的语音伪造防御技术在实际环境中的表现远不如理论预测，未能达到较好的防御效果。

表 2.1 网络媒体广泛采用的有损压缩技术

格式	有损压缩程度	特点
MP3	中等压缩	音质与文件大小之间有良好的平衡，非常适合网络传输
WMA	可变压缩率	支持数字版权管理，经常用于网络流媒体
OGG	高压缩率	主要用于流媒体服务，文件小且调整灵活
AAC	高效压缩	提供更好的音质和更高的编码效率，是多种流媒体平台的首选

因此，我们的 UnVoiceClone 方法特别强调鲁棒性的提升，确保生成的对抗语音在语音传输（包括编解码和有损压缩等）及常见的语音信号处理过程中能保持其稳定性，从而在现实的网络媒体环境中有效发挥主动防御的功能。

在利用 WaveGlow（模型结构见图 2.13）作为 Speech Generator 生成对抗性语音的实验设计中，本作品的策略不单纯聚焦于在声纹隐私防御场景中已经定义的伪装语音。相反，我们团队采取了一种更为精细化的方法，即以一个随机生成的高斯分布为核心，确保原始说话人的真实语音与伪装语音之间达到一个动态的平衡。这种平衡是通过我们团队设计的三个损失函数来实现的，这些函数不仅确保对抗语音在特征层面精准地模拟目标语音，而且在波形层面上与原始语音保持一致性，进一步地，它们严

格遵守高斯分布规律，即保证对抗语音与添加的对抗高斯分布噪声属于同一分布。




图 2.13 WaveGlow 网络架构

WaveGlow 的使用允许我们实现以下几点：首先，该模型可以无缝地处理来自高斯分布的随机噪声输入，这是我们 UnVoiceClone 方法中不可或缺的部分。通过调整噪声输入，WaveGlow 能够在原始语音和伪装语音之间生成动态平衡，同时遵循概率分布的规律，这对于 UnVoiceClone 方法的鲁棒性实现至关重要。其次，WaveGlow 的高效生成能力使我们能够精细调整语音特性，通过设计的损失函数确保对抗性语音在特征层面精准地模拟目标语音，而且在波形层面上与原始语音几乎保持一致，确保语音保真度，不因为添加扰动而影响语音质量。




图 2.14 引入高斯噪声的对抗语音生成

具体来说，UnVoiceClone 生成对抗语音的流程包括以下几个关键步骤：首先，将原始语音转换为梅尔频谱图。接下来，WaveGlow 模型接收这一频谱图，并在此基础上对输入的高斯噪声进行转换和优化。通过三个关键的损失函数进行迭代优化，这三个损失函数分别针对不同的优化目标设计，我们能够逐步调整噪声，以生成与原始语音具有相似特性但能够改变被伪造后特性呈现的对抗语音。

此外，本作品采用的方法与传统对抗语音生成技术存在显著差异。传统技术通常通过直接在原始语音波形中添加噪声来产生对抗语音。这种方法虽然操作简便，但由于对抗扰动与原语音不共享相同的统计特性，因此在语音传输过程中容易受到常见的语音信号处理技术影响，导致对抗效果减弱。

相较于传统方法，UnVoiceClone 中应用的 WaveGlow 模型生成的对抗语音具有明显优势。该模型生成的语音完全基于与原始语音一致的频谱特征，这种方法显著增强了对抗扰动的隐蔽性。因此，即使这些对抗语音遭受社交媒体的有损压缩技术、重采样等多种预处理步骤，它们仍然能保持原有的对抗性特质，不易被识别或消除。这一点突出了 UnVoiceClone 方法在增强对抗语音的鲁棒性和保真度方面的技术优势，使其在面对复杂的语音信号处理环境时，依然能有效维持对抗效果，具有良好的抗克隆能力。

此种方法论的应用，旨在优化对抗性语音的生成，以便它们在保持自然听感的同时，也能在保护声纹隐私的主动防御过程中展现高度的有效性和鲁棒性，不易被简单的信号处理所消除。

下面我们将具体介绍这三个损失函数的构造过程：




图 2.15 UnVoiceClone 防御方法中的三个损失函数

(1) 嵌入损失：

在声音生成和声纹特征保护的技术实现中，嵌入损失（Embedding Loss）扮演着关键角色。此损失函数的主要目的是最小化生成语音的声纹嵌入与目标语音嵌入之间的差异。在对抗性声音生成中，此损失确保生成的语音在声纹特征上能有效地模仿目标语音，刻意生成与原始语音声纹不同但与目标语音声纹相似的语音。

生成语音和目标语音的声纹嵌入向量分别设为 $\mathbf{e}_{\text{adv}}$ 和 $\mathbf{e}_{\text{tgt}}$ 。利用这两个向量，我们定义嵌入损失 L_{emb} 作为向量间欧氏距离的平方和：

$$L_{\text{emb}}(\mathbf{e}_{\text{adv}}, \mathbf{e}_{\text{tgt}}) = \sum_{i=1}^n (\mathbf{e}_{\text{adv}}[i] - \mathbf{e}_{\text{tgt}}[i])^2 \quad (2.9)$$

其中， n 表示嵌入向量的维度，而 $\mathbf{e}_{\text{adv}}[i]$ 和 $\mathbf{e}_{\text{tgt}}[i]$ 是两个向量在第 i 维的元素。

值得注意的是，这些向量都是通过我们精心选择的集成说话人编码器生成的。说话人编码器的选择和配置对于 UnVoiceClone 方法的泛化性至关重要，因为它直接影响到生成的声纹向量的对不同的语音伪造方法的防御效果。在 2.3.4 中，我们将详细探讨说话人编码器的选择对于声纹保护效果的影响，并解释如何优化这些设置以强化 UnVoiceClone 方法的适用性和效果。

(2) 软约束损失：

软约束损失 (Soft Constraint Loss) 用于确保生成语音在波形层面与原始语音保持一定的相似度。该损失函数优雅地平衡了声纹特征的变更与波形的保真度之间的关系，旨在在保护声纹隐私的同时，避免生成语音在听感上与原始语音的差异过大。

软约束损失的计算方式如下所示：

$$L_{\text{soft}}(\mathbf{a}_{\text{orig}}, \mathbf{a}_{\text{adv}}) = \max_i |\mathbf{a}_{\text{adv}}[i] - \mathbf{a}_{\text{orig}}[i]| \quad (2.10)$$

其中， $\mathbf{a}_{\text{orig}}$ 和 $\mathbf{a}_{\text{adv}}$ 分别代表原始语音和生成的对抗性语音， i 遍历所有语音样本的索引。此损失函数捕捉到两个语音之间的最大单点差异，是一个对生成语音保真度的直观度量。

软约束损失在 UnVoiceClone 方法中的对抗性语音生成过程扮演着双重角色：一方面，它确保生成的语音在波形上不会与原始语音有过大的偏离，维护语音的自然度和听众的接受度；另一方面，它允许一定程度上的声纹特征变更，确保声纹隐私得到有效保护。因此，生成的对抗性语音在实现声纹伪装的同时，仍保持足够的原音质量。

(3) 高斯分布逼近损失：

高斯分布逼近损失 (Gaussian Distribution Approximation Loss) 其主要目的是确保模型的输出变量 z 尽可能地符合标准高斯分布。

在具体实施中，该损失函数考虑了模型输出 z 、缩放因子 s 的对数和变换矩阵 W 行列式的对数。损失函数的数学表达如下：

$$L_{\text{gauss}}(z, s, W) = \frac{1}{2\sigma^2} \sum_i z[i]^2 - \sum_j \log s[j] - \sum_k \log |W[k]| \quad (2.11)$$

其中, $z[i]$ 表示向量 z 的第 i 个元素, $\log s[j]$ 是第 j 个缩放因子的对数, 而 $\log |W[k]|$ 是第 k 个变换矩阵的行列式对数。

高斯分布逼近损失的第一项 $\frac{1}{2\sigma^2} \sum_i z[i]^2$ 确保模型输出 z 的分布尽可能接近中心为零、方差为 σ^2 的正态分布。这一项是评价 z 与目标分布相似度的直接度量。通过最小化这一项, 模型被训练以调整其输出, 使其在特征空间中的分布更加规整和可预测。这种广泛性的干扰使得模型在不同的听觉维度上都进行优化, 提高了对抗语音的健壮性, 保证其核心的对抗属性不受影响。

在数字语音处理中, 常见的操作如压缩和重采样可以改变语音数据的统计特性。高斯分布逼近损失通过确保模型输出接近标准高斯分布, 增强了模型对这些变化的不敏感性。这意味着即使在经过如 MP3 或 AAC 这样的有损压缩后, 模型输出的统计特性仍然保持一致, 从而保证了处理输出的质量和一致性。

接下来的两项, $-\sum_j \log s[j]$ 和 $-\sum_k \log |W[k]|$, 则与模型变换的可逆性和效率直接相关。这些项确保了在模型的流变换过程中, 概率密度得以正确调整, 以保持整体变换的概率质量守恒。这种概率守恒性质确保了模型在变换前后保持信息的完整性, 这对于在各种操作 (如压缩、裁剪和编码) 后还能恢复原始信号非常关键。

综上所述, 本作品通过设计三重损失函数, 实现了 UnVoiceClone 方法中对抗语音生成的多维优化。首先, 嵌入损失确保生成语音在声纹特征上与目标语音相似, 从而有效地模仿并保护原始说话人的声纹隐私。其次, 软约束损失强化了生成语音在波形层面上与原始语音的相似性, 维护了语音的自然度和听众的接受度, 同时允许了一定程度的声纹特征变更。最后, 高斯分布逼近损失通过确保模型输出与标准高斯分布的一致性, 提高了模型在面对压缩和重采样等常见语音处理操作时的鲁棒性。

这种综合性的损失函数设计, 不仅提升了对抗语音的生成质量, 也增强了其在实际应用环境中的防御能力, 特别是在网络媒体广泛采用的有损压缩和重采样技术面前。因此, UnVoiceClone 方法不仅在理论上具有优势, 实际的应用效果也显示出其显著的实用性和有效性。

2.3.4 动态权重调整的集成说话人编码器策略

在实现通过引入高斯噪声增强对抗语音生成的方法之后, 初步实验结果显示, 该方法在已知的说话人编码器中表现出优异的防御性能及鲁棒性。然而, 实际应用场景复杂多变, 经常涉及到多种未知的语音伪造模型, 而攻击者可能使用的合成或编码模型常常是未知的, 甚至无法供用户进行黑盒查询。这一现状使得对防御机制的广泛适应性研究成为一项紧迫的需求。尽管当前策略在特定的说话人编码器上通过嵌入损失

优化展现了显著效果，其潜在的局限性不容忽视。具体来说，如果防御策略主要针对单一的说话人编码器进行优化，其泛化能力可能会受限，难以有效应对多元化的攻击环境，如图 2.16 所示。由于大多数对抗语音示例专门针对特定的文本到语音 (TTS) 或说话人识别模型设计，这种专一性所产生的知识差距加剧了在未知模型上开发有效干扰多样化嵌入空间扰动的难度，从而限制了这些防御策略在更广泛应用场景中的有效性。




图 2.16 单一和动态集成说话人编码器在未知伪造场景下的差异

动态权重调整策略是一种在多模型集成攻击中应用的先进方法，其核心目的在于优化各个模型对整体攻击策略的贡献。在声纹识别系统中，该策略尤为关键，因为虽然各个说话人编码器在声学特征的丰富度和嵌入空间大小方面存在差异，但它们都能处理来自不同个体说话者数据集的声音样本，从而展现出其多样性。研究结果指出，对语音信号中固有的声学特征进行深入扰动后，即便在攻击模型未知的黑盒环境中，所生成的说话人嵌入也会显著偏离其原始值。这一变化证明，采用此种策略构造的对抗语音在黑盒模型中能够有效维持其对抗性和泛化性。

然而，不同模型间因内部评分机制（例如 PLDA 和余弦相似度）的不同而导致的输出差异性较大，这一现象表明，简单的平均或等权重集成方法可能无法达到最佳效果。因而，我们希望采用一种策略，可以实现全面的特征提取，极大地提升特征在不同合成器之间的可转移性，以稳健的方式调整和优化这些特征及其嵌入空间。

表 2.2 集成的说话人编码器特性

说话人编码器	架构	层数	嵌入尺寸	数据集 / 说话人数
ECAPA-TDNN	Bottle2neck + MFA	8	192	VoxCeleb 2 / 6000
Style encoder	HiFi-GAN + Diffusion + SLM	16+	128	LibriTTS / 2456
GE2E	LSTM	3 (768 cells)	256	Custom / 18000
d-vector	H/ASP (ResNet + ASP)	34	512	VoxCeleb 2 / 6000

为了克服传统统一权重分配方法在处理多说话人编码器集成时的不足，本作品提出了一种动态权重调整的集成说话人编码器策略。此策略的核心在于通过每个说话人编码器的损失函数的历史统计数据（均值与标准差）来进行归一化处理，从而有效地消除由于各模型损失函数尺度和范围的内在差异所带来的影响。此归一化过程使得不同模型产生的损失能在同一标准下进行比较，进而实现更加科学合理的权重分配。具体来说，我们集成了四种主流的语音合成模型所使用的说话人编码器：ECAPA [52]、Styletts 2 [53]、ResNetSE [54] 以及 Yourtts [55]，并选择了其对应的说话人编码器，如表 2.2 所示。

其中，这些说话人编码器的架构中包含一些关键结构：Bottle2neck 类似于 ResNet 中的 bottleneck 结构，包含输入卷积层、分组卷积、SE 模块和输出卷积层，通过残差连接提高模型的表示能力；MFA（多尺度特征聚合）用于在不同时间尺度上聚合特征；Diffusion 模型用于生成稳定的语音特征，通过在噪声和目标数据之间逐步传递生成高质量语音；SLM（Style Language Model）使用微软的 WavLM-Base-Plus [56] 模型来捕捉语音风格和特征；SAP（自注意力池化）和 ASP（注意力统计池化）是用于加权和聚合特征的自注意力机制，使模型更好地捕捉到说话人的特征。序列模型 LSTM 则用于捕捉长期依赖关系并进行时序建模。

选定上述说话人编码器后，动态权重调整的集成说话人编码器策略具体介绍如下，对于第 k 个说话人编码器，其归一化损失函数定义为：

$$f'_k = \frac{f_k - \mu_k}{\sigma_k} \quad (2.12)$$

其中 $f_k = f(x; R_k)$ 是原始损失函数， μ_k 和 σ_k 分别是该模型损失的滑动均值和滑动标准差。为了动态更新这些参数，在每次迭代中我们使用以下规则：

$$\mu_k = \mu_k + \frac{f_k - \mu_k}{n}, \quad \sigma_k = \sigma_k + \frac{1}{n} ((f_k - \mu_k)^2 - \sigma_k^2) \quad (2.13)$$

其中 n 是当前迭代次数。这种动态更新机制确保了每个模型的权重能够反映其在集成中的实际表现，从而优化 UnVoiceClone 方法在应对黑盒模型伪造时仍具有较强的防御泛化性。

在实际实现过程中，动态权重调整策略在每次迭代过程中对每个说话人编码器的损失进行归一化处理，并动态更新其权重。这些权重通过以下公式计算得到：

$$w_k = \frac{\mu_k}{\sigma_k^2} \quad (2.14)$$

其中, 权重 w_k 反映了第 k 个模型在整体损失中的相对重要性, 这种设计可以确保具有较高波动性且贡献较大的模型在集成中获得适当的权重。

最终, 整个集成模型的损失函数定义为所有归一化损失的加权和:

$$f_{ens} = \sum_{k=1}^K w_k \cdot f'_k \quad (2.15)$$

完整的动态权重调整策略伪算法见算法 1:

Algorithm 1 动态权重调整的集成说话人编码器策略

```

1: 输入: 训练数据集  $D$ , 最大迭代次数  $T$ , 所有说话人编码器集合  $\{R_k\}_{k=1}^K$ 
2: 输出: 更新后的模型参数  $\{\mu_k, \sigma_k\}$ , 权重  $\{w_k\}$ 
3: 初始化滑动均值和标准差:  $\forall k, \mu_k \leftarrow 0, \sigma_k \leftarrow 1$ 
4: 初始化权重:  $\forall k, w_k \leftarrow 0$ 
5: for  $t = 1$  to  $T$  do
6:   for each  $x \in D$  do
7:     for  $k = 1$  to  $K$  do
8:        $f_k \leftarrow f(x; R_k)$  ▷ 计算第  $k$  个模型的损失
9:        $\mu_k \leftarrow \mu_k + \frac{f_k - \mu_k}{t}$  ▷ 更新滑动均值
10:       $\sigma_k \leftarrow \sigma_k + \frac{1}{t} ((f_k - \mu_k)^2 - \sigma_k^2)$  ▷ 更新滑动标准差
11:       $f'_k \leftarrow \frac{f_k - \mu_k}{\sigma_k}$  ▷ 计算归一化损失
12:   for  $k = 1$  to  $K$  do
13:      $w_k \leftarrow \frac{\mu_k}{\sigma_k^2}$  ▷ 计算权重
14:    $f_{ens} \leftarrow \sum_{k=1}^K w_k \cdot f'_k$  ▷ 计算集成模型的损失
15: return  $\{\mu_k, \sigma_k\}, \{w_k\}$  ▷ 返回更新后的参数和权重

```

这种策略能够确保每个模型的权重与其损失的相对波动性和贡献相匹配, 从而最大化对抗性语音样本的生成效果, 增强 UnVoiceClone 方法的泛化性, 确保在多变的应用环境中具备高效的防御能力。

尽管说话人编码器在提取说话人特征时仅生成潜在空间表示, 并且本质上不可解释, 但我们特别关注了四个广为认知的说话人特征提取属性: 梅尔频率倒谱系数 (MFCC) [57]、线性频率倒谱系数 (LFCC) [58]、线性预测编码 (LPC) [59] 以及线谱频率 (LSF) [60]。

我们的旨在分析 UnVoiceClone 动态集成方法与单个说话人编码器在提取特征时的差异与关系。我们采用下列公式计算声音特征的偏差因子, 以评估特定声音特征在抵御语音仿冒攻击中的效用:

$$\text{偏差因子} = \frac{\Delta f_{\text{adv}} - \Delta f_{\text{ctrl}}}{\Delta f_{\text{ctrl}}} \quad (2.16)$$

其中， Δf_{adv} 表示从对抗语音中提取的特征与原始语音特征的差值， Δf_{ctrl} 表示从控制样本中提取的特征与原始语音特征的差值。通过计算两者的差值比，可以得到声音特征改变的相对幅度。这样，高偏差因子值表明该声音特征在区分对抗语音与控制样本方面表现出较高的有效性，因而在防护语音仿冒攻击中尤为重要。

表 2.3 声音特征的平均偏差因子

声音特征	ECAPA-TDNN	Style encoder	GE2E	d-vector	UnVC(动态集成)
MFCC	0.82	0.47	0.28	0.12	0.26
LFCC	0.88	0.58	1.28	0.66	1.04
LPC	0.28	1.33	0.65	1.63	1.22
LSF	0.73	0.29	0.17	0.37	0.24

我们的评估结果表2.3显示，不同的说话人编码器（包括 UnVoiceClone 的动态集成策略）在处理声音特征时的表现各异。例如，GE2E 编码器与 LFCC 特征之间存在紧密的关联，而 Style encoder 主要与 LPC 特征对齐。在所有编码器中，LSF 的表现相对均衡，但偏差因子普遍不高，ECAPA-TDNN 中的表现最为突出。LFCC 和 LPC 在 UnVoiceClone 方法中表现出较高的平均偏差因子，暗示它们可能是主动防御的关键特征。

此外，我们认为没有一个通用的声音特征能在所有说话人编码器中通用，这进一步印证了依赖单一的说话人编码器可能导致次优的防御效果，缺乏我们采用动态集成方法的泛化性优势。这一点突显了 UnVoiceClone 方法的创新性和优势。

2.3.5 基于梯度正则化和锐度感知最小的扰动优化

在实施了动态权重调整的集成说话人编码器策略之后，为了进一步提升 UnVoiceClone 方法的泛化性能，我们深入探讨了对抗语音生成过程中所需考虑的关键因素。特别是，我们注意到在原始语音上进行的微小扰动可以有效地隐藏被伪造时的音色特征，而对抗语音的迁移性主要取决于模型的平滑性与梯度相似性之间的细致平衡。因此，在训练对抗语音时，同时优化模型的平滑度和梯度相似性对于增强泛化性是至关重要的。为此，在 Adam 优化器的基础上，本作品融合**梯度正则化和锐度感知最小化 (SAM) 技术**指导高斯噪声的优化，以期通过这种方式显著提高模型对不同攻击情景的适应性和鲁棒性。

(1) 梯度正则化

最近的研究集中在权重空间中的梯度正则化，这种正则化方法是通过对神经网络中的参数（即权重）进行调控来提升模型的泛化能力。具体来说，这一方法强调对权

重空间中的梯度进行正则化，从而间接促进输入空间的平滑性。这种方法的核心思想是通过控制权重的变化来稳定网络的输出，从而提高模型在未见数据上的表现。




图 2.17 梯度正则化和锐度感知最小化

首先，研究表明在权重空间中施加的梯度正则化压力可以传递到输入空间^[61]。即，如果在权重空间中正则化梯度 $\|\nabla_{\theta} f_{\theta}(x)\|_F$ ，则这种正则化也会影响输入空间中的梯度 $\|\nabla_x f_{\theta}(x)\|_F$ 。因此，对权重空间的梯度进行正则化可以隐式地促进输入空间的平滑性。

在显式梯度正则化（Explicit Gradient Regularization, ER）方法中，将关于参数 θ 的梯度的欧几里得范数添加到训练损失函数中，以促进权重空间的平滑性。具体地，ER 方法将原始目标函数 $L(\theta)$ 修改为：

$$L_{er}(\theta) = L(\theta) + \frac{\lambda_{er}}{2} \|\nabla_{\theta} L(\theta)\|^2, \quad (2.17)$$

其中 $L(\theta)$ 是原始的目标函数， λ_{er} 是一个控制正则化强度的超参数。通过添加这一项，模型在训练过程中不仅最小化原始损失函数，还同时最小化梯度的欧几里得范数，从而促使权重空间中的解更加平滑。

(2) 锐度感知最小化融合

锐度感知最小化（Sharpness-Aware Minimization, SAM）也是一种旨在找到权重空间中平滑解的方法。具体来说，SAM 通过在每次参数更新时寻找权重空间中对损失函数变化最敏感的方向，并在该方向上进行调整，从而提升模型的泛化能力。其目标是同时最小化原始训练损失和最坏情况下的损失“锐度”。SAM 的目标函数定义为：

$$L_{sam}(\theta) = L(\theta) + \left[\max_{\|\hat{\theta} - \theta\|_2 \leq \rho} L(\hat{\theta}) - L(\theta) \right], \quad (2.18)$$

其中， ρ 表示搜索最坏邻居的半径。

在实现过程中，SAM 使用两次近似来更新梯度：

$$\nabla_{\theta} L_{sam}(\theta) \approx \nabla_{\theta} L(\theta + \rho \frac{\nabla_{\theta} L(\theta)}{\|\nabla_{\theta} L(\theta)\|}). \quad (2.19)$$

具体而言，首先计算当前参数 θ 的梯度，并沿着梯度方向寻找一个半径为 ρ 的扰动。然后在这个扰动后的参数上重新计算梯度，最终得到更新后的梯度。这一过程可以理解为先寻找损失函数对权重最敏感的方向，然后在这个方向上进行参数更新，从而找到一个更加平滑且更具泛化能力的解。

SAM 作为一种特殊的梯度归一化方法，其中 ρ 表示正则化的大小^[62]。在实际应用中，SAM 不仅能够提升我们的 UnVoiceClone 方法在训练数据上的表现，更能够在未见数据上保持较高的泛化性。

最后，基于 SAM 指导高斯噪声的优化，对原始噪声 X 在其邻域范围内随机扰动作为算法初始输入，经多次迭代后生成具有对抗效应的高斯噪声分布 X^{N+1} 。

$$\begin{cases} X^0 = X \\ L = \text{SAM}[L_{\text{emb}}] + \lambda \text{SAM}[L_{\text{gauss}}] + \beta \text{SAM}[L_{\text{soft}}] \\ X^{N+1} = \{X^N + \epsilon \nabla_X L_{\text{sam}}(X)\} \end{cases} \quad (2.20)$$

2.3.6 面向社交媒体的音视频主动防御系统实现

当前，通过社交媒体的音视频分享是声纹被窃取的主要原因，为进一步将技术落地，本作品面向社交媒体的音视频，融入基于 CNN 的 inaSpeechSegmenter 模型来精准定位语音中说话人的信息，包括说话时间段、说话人性别，再结合多线程技术并行使用 UnVoiceClone 模型处理各说话人语音片段，最后联结语音并还原。




图 2.18 面向社交媒体的主动防御系统

(1) inaSpeechSegmenter 确定说话人信息

如果输入的是视频，则需要先提取语音信息，将提取出的语音输入到 inaSpeechSegmenter，inaSpeechSegmenter 首先基于 CNN 的语音分段模型确定说话人、音乐、空

白等片段的起始和结束时间，然后使用通用语音特征 MFCC 提取框架计算与各语音片段相对应的特征。最后使用 GMM 对语音特征进行初步建模，提取 i-vector 作为特征表示，最后使用 CNN 进行性别分类，将对应的说话人语音片段分类为男性和女性。

(2) UnVoiceClone 多线程并行

根据 inaSpeechSegmenter 输出的说话人信息，可以精准定位说话人语音片段以及其性别，以提高 UnVoiceClone 模型防御速率。且采用多线程并行技术，大幅提高系统的算法运行效率。

通过采用上述方法，我们显著提升了 UnVoiceClone 系统在社交媒体音视频声纹防御方面的运行效率，并进一步增强了其应用价值。

第三章 作品测试与分析

在防御语音的性能评估中，干扰能力和保真度同样关键，不仅要考虑防御语音与原始语音说话人特征变化较小，还应该考虑防御语音对 TTS 和 VC 模型具有一定的干扰能力。此外，本章结合作品特色，将对 UnVoiceClone 系统生成的防御语音进行鲁棒性和泛化性测试。




图 3.1 系统测试方案设计

3.1 测试环境

3.1.1 设备环境

表 3.1 测试硬件环境

设备	配置
CPU	12th Gen Intel(R) Core(TM) i9-12900K
内存	128GB
GPU	NVIDIA V100 Tensor Core GPU
显存	32GB

表 3.2 测试软件环境

软件	配置
Python	3.7
依赖项	见附件 requirement.txt

表 3.3 网页应用系统开发环境

软件	技术配置
后端配置	flask
前端配置	HTML、JavaScript、CSS
开发工具	Visual Studio Code
操作系统	Windows 11

3.1.2 数据集

经过相关调研，测试时选用 VCTK^[63]、LibriSpeech^[64]、TIMIT^[65] 数据集

因此，我们随机抽取数据样本库语音，自定义 UnVoiceClone 数据集包括 90 个说话人，每个源语料库中有 30 个说话人，每个说话人有 5 个短（3-4s）到长（6-7s）的语音样本。

VCTK^[63]：CSTR VCTK 数据集包含 109 名具有各种口音的英语使用者生成的超过 44 小时的语音数据。录制的短语来自不同的文本材料，包括报纸、语言文本和语音丰富的句子。

LibriSpeech^[64]：LibriSpeech 是一个包含大约 1,000 小时英语语音的大型语料库。我们使用 test-clean 子集，其中包含 40 名英语使用者的口语短语。

TIMIT^[65]：TIMIT 包括来自美国英语八种主要方言的 630 名发言者的录音，每个发言者阅读 10 个语音丰富的句子。

如表3.4所示，选择的语音样本涵盖了一套全面的语音内容、样本长度以及具有广泛性别、年龄组、地区和口音的说话者。

表 3.4 UnVoiceClone 测试数据集

来源	说话人（男/女）	年龄范围	口音	平均时长
VCTK	30 (13/17)	18-38	American, Australian, Canadian, English, Indian, Irish, NewZealand, NorthernIrish, Scottish, SouthAfrican, Welsh.	4.78 s
Librispeech	30 (14/16)	-	-	4.70 s
TIMIT	30 (15/15)	-	American (New England, Northern, North Midland, South Midland, Southern, New York City, Western, Moved around)	3.11 s

3.1.3 评估指标

防御语音除了需要满足抗克隆能力，也需要满足信息的正确传递，所以生成对抗样本要保证在人耳的识别系统下成功转录的正确性。我们团队为了测试语音保真度损失情况，采用主客观结合，主观上让多名听众对语音进行评价，并计算 MOS 分数，客观上采用了 CER、ASV、PESQ 等指标来量化语音的质量情况。同时，为了 UnVoiceClone 语音的抗克隆能力，也采用主客观结合，主观上让多名听众对语音进行评价，并计算 PSD 分数，客观上采用了 Defend 等指标来量化抗克隆能力。

为研究主动防御技术对语音的影响程度，本作品选取以下指标评估防御后语音的保真度以及和原始语音之间的相似度。

(1) 说话人相似度 ASV

为了改善防御后的保真度，使得防御后语音说话人与原始语音的相似度尽可能大，我们团队采用说话人相似度 **ASV**，来衡量防御前后语音的相似度。

说话人相似度 **ASV** 的含义为防御前后语音特征向量的余弦相似度。这一指标反映了语音的防御处理对语音特征保持的程度，相似度越高，表示防御对语音特征的保护越好。主要用于评估语音内容在经过防御处理后与原始语音的保持程度。高相似度表明防御技术能有效保留原始语音的特征，因此在保护用户隐私的同时不损害语音的可用性和清晰度。其计算公式见下方：

$$ASV = \frac{\vec{v}_{\text{original}} \cdot \vec{v}_{\text{defended}}}{\|\vec{v}_{\text{original}}\| \|\vec{v}_{\text{defended}}\|} \quad (3.1)$$

其中， $\vec{v}_{\text{original}}$ 和 $\vec{v}_{\text{defended}}$ 分别代表原始和防御后提取的语音特征向量。这一公式通过计算两个向量之间的余弦角度，来量化它们之间的相似性。

(2) 语音内容 CER/WER

为了尽可能使得防御后的语音内容与原始语音一致，不发生错误，我们团队采用语音内容 CER/WER 来衡量防御后语音的内容错误率。

语音内容 CER/WER 包括字符错误率 (CER) 和词错误率 (WER)，是衡量语音识别系统输出与参考文本之间差异的标准指标。这些指标反映了语音内容在防御处理后的准确性，是评估语音系统性能的关键因素。较低的 CER/WER 表示防御系统在不影响语音内容准确性的前提下有效地保护了语音数据。其计算公式见下方：

$$CER = \frac{\text{插入错误数} + \text{删除错误数} + \text{替换错误数}}{\text{参考文本中的字符总数}} \quad (3.2)$$

$$\text{WER} = \frac{\text{插入错误数} + \text{删除错误数} + \text{替换错误数}}{\text{参考文本中的词总数}} \quad (3.3)$$

这些公式通过对比原始文本和识别结果中的差异，来计算错误率，从而为我们团队尽可能降低错误率的目标提供数据指标依据。

(3) 语音质量感知 PESQ

为了确保防御后语音保真度的可用性，我们团队采用语音质量感知 PESQ 指标，来客观衡量生成的防御语音质量。

PESQ 是由国际电信联盟（ITU）标准化的一种方法，用于客观评估语音通信系统中的语音质量。这种评估方法模拟人的听觉特性来测量语音样本的清晰度和自然度，特别适用于评价语音编解码器（Codecs）和其他语音处理设备对语音质量的影响。PESQ 为语音质量提供一个从 -0.5 到 4.5 的评分，其中 4.5 表示几乎无损的完美质量，而 -0.5 分则指示质量极差。

PESQ 的输出评分由以下公式给出，该公式考虑了多种人耳听觉特性：其中，MOS-LQO（Mean Opinion Score Listening Quality Objective）是基于客观听觉模型的评分。

$$\text{PESQ Score} = 4.5 - \text{MOS-LQO} \quad (3.4)$$

(4) 语音自然度 MOS

为了更加主观性，获得贴近自然人的评价指标，我们团队采用语音自然度 MOS 作为防御语音质量的主观评价指标。

MOS（Mean Opinion Score）提供了一个量化的方法来评估听众对语音样本自然度的感知。它是衡量语音处理系统，尤其是在进行声音修改或防御操作后，对于语音自然性保持程度的重要指标。MOS 通常用一个在 1-5 范围内的有理数表示，其中 1 表示最低感知质量，5 表示最高感知质量，具体范围及其对应的标签和意义详见评级量表 3.5。MOS 的高值表示对于语音自然性保持程度好，能有效隐藏经过防御的事实，并且增强语音的可用性。

表 3.5 语音自然度 MOS 评级量表

指标	标签	意义
1	不合格	几乎完全听不清
2	较差	有明显的噪声干扰，较不清晰
3	一般	能感知到的噪声
4	良好	有噪声，但不影响收听
5	优秀	几乎无损的音质体验

每一位自然人评分者通过分别收听原始语音和防御语音，完成主观质量评估测试，根据评级量表的指示，给出相应的分数。最后 MOS 的计算公式见下方， R_n 表示受试者所给出的分数， N 表示受试者样本数量：

$$MOS = \frac{\sum_{n=1}^N R_n}{N} \quad (3.5)$$

同时为研究主动防御技术对 TTS 和 VC 模型的干扰程度，我们团队使用了以下指标来评估。

(1) 防御成功率 Defend

为了尽可能使得原始语音与防御语音输入到语音克隆模型得到的合成语音之间的差异扩大，从而达到无法合成正确目标说话人的声音，定义防御成功率 *Defend* 来衡量两者差异。

Defend 计算时，首先计算原始语音与防御语音通过语音克隆模型生成的合成语音之间的特征向量余弦相似度，然后取该相似度的补值（即 1 减去相似度值）。其基本原理和说话人相似度 *ASV* 是一致的，但是追求效果是截然相反的，应当使得语音说话人相似度越低越好，这样 *Defend* 就越高。其计算公式见下方：

$$\text{Defend} = 1 - \frac{\vec{v}_{\text{original}} \cdot \vec{v}_{\text{clone}}}{\|\vec{v}_{\text{original}}\| \|\vec{v}_{\text{clone}}\|} \quad (3.6)$$

其中， $\vec{v}_{\text{original}}$ 和 $\vec{v}_{\text{clone}}$ 分别代表原始语音和防御语音通过模型所合成语音的特征向量。这一公式通过计算两个向量之间的余弦角度，来量化它们之间的相似性。对于这个相似度，我们希望越低越好，*Defend* 才会越高。

(2) 感知说话人不相似度 PSD

在采用 *Defend* 来衡量原始语音与防御语音输入到语音克隆模型得到的合成语音之间的差异的基础上，我们团队选用 PSD 作为衡量两者差异的主观评价指标。

感知说话人不相似度 PSD 是在体验质量和通信工程领域中所使用的评价指标，其含义是由自然人主观性地来评估防御语音通过语音克隆模型得到的合成语音和原始受害者语音之间的身份差异。PSD 通常用一个在 1-5 范围内的有理数表示，其中 1 表示最低感知质量，5 表示最高感知质量，具体范围及其对应的标签和意义详见评级量表3.6。PSD 的高值表示抗克隆能力好，能有效隐藏或改变原始说话人的特征，从而保护说话人的身份不被轻易识别。

表 3.6 感知说话人不相似度 PSD 评级量表

指标	标签	意义
1	不合格	听众几乎无法区分两者之间的差异
2	较差	听众能够感觉到很多相似性，少数特征有所不同
3	一般	存在一些明显的相似性，但也有辨识出的不同
4	良好	听众感觉到轻微的相似性，但总体上差异显著
5	优秀	听众几乎无法识别出任何相似性

每一位自然人评价者通过收听原始语音输入到语音克隆模型得到的合成语音，以及防御语音输入到语音克隆模型得到的合成语音，完成主观质量评估测试，根据评级量表的指示，给出相应的分数。最后 PSD 的计算公式见下方， S_n 表示受试者所给出的分数， N 表示受试者样本数量：

$$PSD = \frac{\sum_{n=1}^N S_n}{N} \quad (3.7)$$

3.1.4 测试模型选取

本作品通过将 UnVoiceClone 的抗克隆能力与先前工作在白盒环境和黑盒环境下进行比较。为了最好地模仿具有先进 DeepFake 技术的强大攻击者，我们专注于基于 DNN 的语音克隆模型，且具有最先进的零样本触发功能。在检查各模型的性能后，选择了以下六个语音克隆模型。

在白盒场景下，我们知道语音转换说话人编码器的结构和所有参数，并直接生成目标语音转换模型的对抗样本，根据编码器对语音特征的提取能力和模型架构，本作品选取 YourTTS 和 StyleTTS 作为白盒模型。

YourTTS(ICML 2022) ^[55]：YourTTS 是一个 Zero-shot 多说话人 TTS 系统，具有多语言功能，于 2022 年推出。它由三个主要组件组成：作为说话人编码器的 H/ASP 模型，作为解码器的自定义 VITS 模型，以及作为声码器的 HiFi-GAN。首次将多语言的方法应用于零样本多说话人语音克隆技术中。

StyleTTS 2(NIPS 2023) ^[53]：StyleTTS 2 是一个利用语音属性（语调、音色、情感）扩散和对抗训练结合大型语音语言模型的文本到语音（TTS）模型。与前身不同，StyleTTS 2 通过扩散模型将语音属性建模为潜在随机变量，从而生成最适合文本的风格音。StyleTTS 2 在单人说话者 LJSpeech 数据集上合成效果超越了人类录音，而在多说话者 VCTK 数据集上与之匹敌，得到了英语为母语的人的认可。此外，当在 LibriTTS 数据集上训练时，模型优于先前公开可用的 Zero-shot 说话人自适应模型。

此外，本作品还选择了四种高精度的语音转换模型用于评估 UnVoiceClone 方法的性能。这些语音转换系统包括最新的商业模型和开源模型，但从对抗样本知识角度出发，以下四种对于防御者而言都是黑盒的。

LVC-VC(Interspeech 2023)^[66]: LVC-VC, 一种端到端的零样本语音转换模型, 利用位置可变卷积 (LVC) 共同建模语音转换和语音合成过程。LVC-VC 使用精心设计的输入特征来分离内容和说话人信息, 并通过类似神经声码器的架构高效结合这些特征, 直接合成时域语音, 在语音风格转换和语音清晰度之间表现出良好的平衡。

VALL-E(Microsoft 2023)^[16]: VALL-E X 是微软研究院开发的一个创新的多语言文本转语音 (TTS) 模型。这个模型不仅能够进行高质量的语音合成, 还能够实现零样本语音克隆, 即仅通过一段简短的录音 (3 到 10 秒), 就能够复制并模仿特定说话者的声音,VALL-E X 支持多种语言, 包括英语、中文和日语, 能够进行自然、富有表现力的语音合成。用户只需提供一段简短的录音, 模型就能够生成与录音中说话者声音极为相似的语音。合成的语音不仅在音色上与原声相似, 而且在情感表达上也保持一致。

XTTS2(CoquiAI 2023)^[67]: XTTS2 是由 CoquiAI 团队开发的一个非常强大的文本转语音模型, 只需一个 3 秒的语音片段, 就可以克隆不同语言的声音。基于 Tortoise 模型, XTTS2 进行了重要的模型改进, 使得跨语言的声音克隆和多语言的语音生成变得非常容易, 不需要大量的训练数据, 也不需要花费数小时进行训练。

ElevenLabs(ElevenLabs 2023)^[68]: ElevenLabs 是一个新资助的商业产品, 专门研究包括 TTS 在内的多功能人工智能语音技术。自 2023 年其 beta 平台发布以来, 它已经获得了极大的知名度, 甚至在 DeepFake 中被滥用来传播错误信息和仇恨言论。ElevenLabs 是一个完全黑盒的语音克隆工具。

3.2 保真度与抗克隆能力测试

表 3.7 保真度与抗克隆能力测试方案

评估对象	评估方式	评估目的	评估指标
保真度	客观	测试防御前后语音说话人相似度	ASV
	客观	测试防御后语音的内容错误率	CER/WER
	客观	测试防御后语音的清晰度和自然度	PESQ
	主观	听众对防御语音自然度的感知结果	MOS
抗克隆能力	客观	原始语音与防御语音输入到语音克隆模型得到合成语音之间说话人差异	Defend
	主观	防御语音通过语音克隆模型的合成语音和原始语音之间的身份差异	PSD

在白盒场景下，语音克隆模型的结构和参数都是已知的，并且可以直接生成目标语音转换模型的对抗样本。而在黑盒场景下，对其内部结构和参数则完全未知。本作品在测试时，将生成防御语音应用于白盒模型与黑盒模型进行抗克隆能力的测试，同时，将 UnVoiceClone 的抗克隆能力与先前的工作 **emb attack (IEEE SLT 2021)** [69]、**AntiFake (CCS 2023)** [50] 进行对比分析，实验时控制使用相同的说话人编码器进行训练。

为了减少语音转换模型表现的影响，我们筛选出在 $\epsilon = 0$ 时未能正确执行语音转换的样本，即剔除异常语音。因此，**数据集中所有参数 $\epsilon = 0$ 的样本并没有抗克隆能力，表示未经过任何处理的原始语音。**

由于使用了编码器集成攻击技术，为全面与先前工作对比、研究集成的说话人编码器与单说话人编码器的抗克隆能力差异并评估 UnVoiceClone 在各种情况下的抗克隆能力，本组进行了说话人编码器集成攻击的消融研究，如下所示。

- 情景①：攻击的模型仅为 YourTTS
- 情景②：攻击的模型仅为 StyleTTS2
- 情景③：集成的说话人编码器为 YourTTS+StyleTTS2
- 情景④：集成的说话人编码器为 YourTTS+StyleTTS2+LSTM
- 情景⑤：集成的说话人编码器为 YourTTS+StyleTTS2+ECAPA TDNN
- 情景⑥：集成的说话人编码器攻击（ECAPA TDNN+YourTTS+StyleTTS2+LSTM）

3.2.1 客观评估

通过上述实验结果表3.8，可以得出以下结论。

(1) 集成说话人编码器技术有助于 UnVoiceClone 抗克隆能力的增强




图 3.2 消融实验中各方法 Defend 指标变化情况

表 3.8 编码器集成攻击的消融研究实验结果

Model	Method	ASV↑	CER↓	WER↓	PESQ↑	Defend↑	
						yourtts	styletts2
①	none ($\epsilon = 0$)	100%	3.01%	8.09%	4.64	6.78%	5.42%
	emb attack [69]	89.70%	4.55%	10.37%	3.76	69.19%	5.81%
	AntiFake [50]	79.40%	6.84%	14.56%	1.65	78.09%	13.21%
	UnVoiceClone	88.32%	4.26%	10.42%	3.36	82.16%	16.58%
②	none ($\epsilon = 0$)	100%	3.01%	8.09%	4.64	6.78%	5.42%
	emb attack	87.89%	5.13%	12.77%	3.42	10.57%	59.08%
	AntiFake	78.26%	6.73%	15.23%	1.68	16.39%	70.67%
	UnVoiceClone	86.45%	5.34%	12.75%	2.94	20.22%	80.12%
③	none ($\epsilon = 0$)	100%	3.01%	8.09%	4.64	6.78%	5.42%
	emb attack	86.03%	4.79%	11.68%	3.61	70.82%	63.59%
	AntiFake	77.11%	7.60%	15.86%	1.87	80.48%	69.87%
	UnVoiceClone	87.61%	4.99%	12.09%	3.25	84.11%	81.56%
④	none ($\epsilon = 0$)	100%	3.01%	8.09%	4.64	6.78%	5.42%
	emb attack	85.29%	5.31%	13.03%	3.08	66.49%	58.12%
	AntiFake	77.26%	7.35%	16.07%	1.90	76.37%	72.16%
	UnVoiceClone	86.03%	5.01%	12.44%	3.22	84.56%	82.72%
⑤	none ($\epsilon = 0$)	100%	3.01%	8.09%	4.64	6.78%	5.42%
	emb attack	85.03%	5.42%	12.69%	2.99	66.68%	63.81%
	AntiFake	76.33%	7.02%	15.93%	1.72	72.12%	71.39%
	UnVoiceClone	84.92%	5.52%	13.07%	3.04	85.17%	83.19%
⑥	none ($\epsilon = 0$)	100%	3.01%	8.09%	4.64	6.78%	5.42%
	emb attack	82.81%	5.44%	13.72%	2.84	65.28%	56.18%
	AntiFake	74.05%	10.63%	17.74%	1.54	79.24%	73.72%
	UnVoiceClone	84.73%	5.36%	13.57%	3.10	87.75%	85.83%

多模型集成攻击，对于图像分类对抗样本上有很好的增强效果。但通过观察图3.2的 *Defend* 变化趋势，可以发现，emb attack 和 AntiFake 在集成更多说话人编码器的过程中，与使用单说话人编码器攻击相比，它的有效性有限，有时甚至降低了抗克隆能力，可能是因为不同的说话人编码器产生的损失结果范围和量表不同。由于损失函数对分数的依赖性，损失函数在范围和尺度上也随集成说话人编码器而变化。因此，均匀的权重使得优化更多地集中在具有大损耗的说话人编码器上，而不是具有小损耗的说话人编码器，这无疑降低了集成说话人编码器的效果。

而本作品自适应地选择适当的权重来平衡不同的损失项，使每一个说话人编码器都能均衡优化，充分利用了集成多说话人编码器提取的说话人特征在模型架构中更加全面这一优势，实验结果也证明 UnVoiceClone 抗克隆能力在集成多说话人编码器时呈上升趋势。

(2) 集成说话人编码器技术对 UnVoiceClone 防御语音的保真度影响较小

另一个观察结果是，上述三种方法集成更多编码器时，保真度评估指标有不同程度地降低，ASV 变化趋势如图3.3所示。原因是当组合更多编码器形成一套全面的声学特征时，通常需要更多的扰动来充分破坏它们，从而导致相对较低的保真度。




图 3.3 消融实验中各方法 ASV 指标变化情况

但本作品的方法,通过梯度正则化和锐度感知最小化技术融合替代传统 PGD 算法来指导高斯噪声的优化,于保真度和抗克隆能力之间实现细致平衡,并通过 WaveGlow 合成高质量防御语音,最终促使下降的趋势相比其他方法更加缓慢。

(3) UnVoiceClone 生成的防御语音兼具保真度与抗克隆能力

由表3.8中大量实验数据可知,融入动态集成的说话人编码器攻击、梯度正则化和锐度感知最小化等方法的 UnVoiceClone 生成的防御语音在保真度和抗克隆能力都优于先前方法,防御评估结果较当前最优的 AntiFake 平均提升了 **10.33%**。

3.2.2 主观评估

上述测试是客观的,但不一定是充分的,它们可能无法完全捕捉人类主观感知的细微差别。语音的质量和体验是涉及人类听觉系统的复杂反应,不同的人对语音的感知可能会有很大差异。根据以上情况,本作品还进行了主观评价。

在主观评估中,测试了基于集成说话人编码器攻击的各防御方法 MOS 和 PSD 评分,本作品邀请了包括 8 组男生和 8 组女生在内的 16 组志愿者进行了测试,每组由 5 名测试者组成。测试时,每位志愿者将从测试数据集中随机抽取 10 条语音样本进行打分,分析每组志愿者打分的平均值。

如图3.4所示,从评分结果可以得出 UnVoiceClone 与 emb attack 方法得到的防御语音语音质量区别不大,但比 AntiFake 语音质量评分更高。同时本作品 MOS 均值为 3.8 左右,表明生成的对抗样本语音质量良好,不会影响人耳识别语音信息。




图 3.4 语音质量 MOS 评估

同时，志愿者也评估了防御语音通过语音克隆 YourTTS 模型得到的合成语音和原始受害者语音之间的身份差异，即进行了 PSD 评分，如图3.5所示，UnVoiceClone 抗克隆能力优于先前的工作，异性身份替换技术的融入，使得志愿者能够明显地感觉到防御语音通过语音克隆模型后合成语音与原始语音的差异。




图 3.5 抗克隆能力 PSD 评估

通过主观指标评估后，也可以得到结论：与先前的工作相比，**UnVoiceClone** 保留高保真度的同时，同样表现了比较好的抗克隆能力，**PSD** 评估结果较当前最优的 **AntiFake** 方法提升了 **0.28**。

3.2.3 扰动程度 ϵ 影响

扰动程度 ϵ 是对抗样本生成中的关键参数之一。在实验过程中，研究了不同扰动程度 ϵ 对 **UnVoiceClone** 抗克隆能力的影响。结果如图 3.6 所示，可以明显观察到，当 ϵ 增加时，抗克隆能力也随之增强。这是因为较大的 ϵ 迫使优化过程引入更显著的嵌入偏差，从而提高防御强度。

然而，增加 ϵ 也会带来显著的副作用，即衡量语音保真度的 **ASV**、**WER**、**PESQ** 等相关指标急剧下降。这是由于更大的扰动会在原始语音上添加更多的噪声，从而影响语音的清晰度和自然度。

经过大量实验验证，我们发现当扰动程度 ϵ 设置为 **0.15** 时，可以在抗克隆能力和保真度之间达到较好的平衡。在这一参数设置下，通过微小的语音变化，**UnVoiceClone** 能够实现强有力的抗克隆能力，同时保持较高的语音保真度。




图 3.6 扰动程度 ϵ 对评估指标的影响

3.3 泛化性测试

表 3.9 UnVC 泛化性测试方案

评估对象	测试模型	评估目的	评估指标
抗克隆能力	lvcvc	测试通过各黑盒模型 克隆后语音和真实语音的差异性	Defend PSD
	elevenlabs		
	valle		
	xttsv2		

在黑盒场景下，对语音转换模型一无所知，只能将在白盒场景下生成的对抗样本转移到该场景进行防御。而本作品选取的测试黑盒模型与白盒场景下集成的模型结构完全不相同。为研究 UnVoiceClone 的泛化能力，此次测试中不再重述保真度的实验结果，主要关注抗克隆能力，通过 **Defend** 和 **PSD** 主客观结合的评估方式，并与先前工作进行对比，展开对 UnVoiceClone 泛化性研究。此处 PSD 结果取所有志愿者 PSD 评分的均值。

如表3.10所示，UnVoiceClone 在黑盒攻击场景下的抗克隆能力也优于先前的工作 **emb attack** 和 **AntiFake**，分别提升了 20.69%、13.2%，实现了更符合实际的通用场景下的防御。

表 3.10 未知黑盒模型场景下的抗克隆能力

Method	Defend↑				PSD↑			
	lvc vc	elevenlab	vall-e	xtts2	lvc vc	elevenlab	vall-e	xtts2
none ($\epsilon = 0$)	4.23%	5.49%	12.08%	2.98%	0.37	0.51	1.05	0.36
emb attack [69]	44.08%	43.79%	50.79%	43.74%	2.32	2.16	2.89	2.21
AntiFake [50]	64.19%	51.69%	49.74%	46.75%	3.19	3.01	2.78	2.73
UnVoiceClone	76.29%	68.14%	59.64%	61.07%	3.83	3.64	3.56	3.28

通过实验数据可以发现，引入集成了梯度正则化和锐度最小化感知的 SAM 优化器后，防御语音的泛化能力显著提升。为验证梯度正则化和锐度最小化感知的效果，我们进行了对比实验，测试了 UnVoiceClone 在使用 PGD 算法、Adam 优化器和 SAM 优化器时，对黑盒模型的泛化能力。

- **PGD 算法**：对原始样本在其邻域范围内随机扰动作为算法初始输入，经多次迭代后生成对抗样本，**emb attack** 和 **AntiFake** 都采用此算法来指导防御语音的生成。
- **Adam 优化器**：利用自适应学习率和动量，更快找到对抗样本，具有快速收敛和在高维空间中表现优异的特点。
- **SAM 优化器**：在 Adam 优化器的基础上融入梯度正则化和锐度最小化感知。使得优化过程能够找到一个平坦的最优解，从而提高在未见模型上的泛化能力。




图 3.7 对抗扰动优化算法对 UnVoiceClone 泛化能力 Defend 影响

图3.15结果表明，SAM 优化器对 UnVoiceClone 防御语音的泛化能力平均提升了 8.875%，有效对抗黑盒模型。

3.4 鲁棒性测试

表 3.11 UnVC 鲁棒性测试方案

评估对象	测试模型	鲁棒测试	评估目的	评估指标
抗克隆能力	lvvc	重采样	测试在各种鲁棒测试情况下 通过黑盒模型克隆后 所得到语音和真实语音的差异性	Defend PSD
	elevenlabs	剪裁		
	valle	加噪		
	xtts2	MP3 压缩		
	yourtts	AAC 压缩		
	styletts2	主流社交平台上传		

当防御语音上传到抖音等网络平台时，由于防御语音在传输过程中会经过一系列处理，原始防御语音被修改、剪裁、加噪、压缩后可能丢失对抗能力，因此对本技术的鲁棒性，即能够抵御外界干扰的能力提出了挑战。

为此，在下述测试中，通过以下处理来检验防御语音的鲁棒性。对于压缩方式选择，实验时选取了最常见的 MP3 压缩以及当前视频平台（抖音和快手）的常用压缩方法 AAC。

重采样 (Resample)：改变语音的采样率，影响语音质量。

剪裁 (Crop)：去除语音的部分内容，可能丢失信息。

表 3.12 经过鲁棒处理后白盒场景抗克隆能力

Robust	Method	Defend $\uparrow$		PSD $\uparrow$	
		yourtts	styletts2	yourtts	styletts2
none	none ($\epsilon = 0$)	6.78%	5.42%	0.68	0.36
	emb attack [69]	65.28%	56.08%	3.39	2.99
	AntiFake [50]	79.24%	73.72%	3.97	3.55
	UnVoiceClone	87.75%	85.83%	4.67	4.46
Resample	none ($\epsilon = 0$)	7.61%	6.29%	0.68	0.44
	emb attack	60.61%	50.37%	3.01	2.87
	AntiFake	76.74%	69.81%	3.73	3.71
	UnVoiceClone	85.87%	84.56%	4.68	4.36
Crop	none ($\epsilon = 0$)	6.79%	5.74%	0.37	0.49
	emb attack	57.61%	54.37%	3.33	3.26
	AntiFake	58.74%	59.64%	3.09	2.91
	UnVoiceClone	80.87%	79.39%	4.11	3.96
Noise	none ($\epsilon = 0$)	8.09%	3.49%	0.31	0.48
	emb attack	56.88%	50.75%	3.36	2.87
	AntiFake	35.74%	33.61%	1.83	1.67
	UnVoiceClone	82.78%	81.46%	4.46	4.29
32k MP3	none ($\epsilon = 0$)	16.79%	19.74%	1.08	1.19
	emb attack	32.61%	30.37%	1.79	1.87
	AntiFake	53.74%	48.64%	2.83	2.65
	UnVoiceClone	71.27%	68.71%	3.68	3.26
32k AAC	none ($\epsilon = 0$)	5.44%	8.61%	0.47	0.86
	emb attack	59.59%	54.41%	3.21	3.19
	AntiFake	68.74%	61.33%	3.63	3.15
	UnVoiceClone	80.22%	77.39%	4.10	3.81

加噪 (Noise Flooding)：添加背景噪音，模拟环境干扰。

压缩 (MP3 和 AAC)：都为有损压缩，减小文件大小但可能影响音质。两种压缩方式可以设置不同比特率压缩处理，比特率越低压缩后音质越差（正常压缩比特率为 64k）

本次实验在白盒环境和黑盒环境的鲁棒性测试结果如下表3.12、3.13所示。同样地，通过 **Defend** 和 **PSD** 主客观结合的评估方式来度量抗克隆能力。在实验中，为了形成对照，也记录了未经过任何处理的原始语音的测试结果。

通过分析上述白盒与黑盒场景下的实验结果，可以得出以下结论：

(1) 重采样、剪裁、加噪处理后，UnVoiceClone 的抗克隆能力表现出微小的下降幅度，Defend 平均降低幅度为 8.60%，而 AntiFake 面对剪裁、加噪处理时 Defend 平均降低幅度为 41.57%，emb attack 平均下降幅度为 18.97%

表 3.13 经过鲁棒处理后黑盒场景抗克隆能力

Robust	Method	Defend $\uparrow$				PSD $\uparrow$			
		lvc vc	eleven	vall-e	xtts2	lvc vc	eleven	vall-e	xtts2
none	none ($\epsilon = 0$)	4.23%	5.49%	12.08%	2.98%	0.37	0.51	1.05	0.36
	emb attack [69]	44.08%	43.79%	50.79%	43.74%	2.32	2.16	2.89	2.21
	AntiFake [50]	64.19%	51.69%	49.74%	46.75%	3.19	3.01	2.78	2.73
	UnVoiceClone	76.29%	68.14%	59.64%	61.07%	3.83	3.64	3.56	3.28
Resample	none ($\epsilon = 0$)	4.64%	3.54%	9.48%	3.22%	0.49	0.51	0.76	0.28
	emb attack	42.79%	43.58%	48.85%	44.63%	2.25	2.36	2.52	2.14
	AntiFake	61.82%	49.61%	50.35%	44.28%	3.25	2.68	3.27	2.62
	UnVoiceClone	74.87%	66.71%	58.09%	59.68%	3.93	4.04	3.84	3.17
Crop	none ($\epsilon = 0$)	6.85%	5.39%	7.88%	3.22%	0.19	0.21	0.46	0.34
	emb attack	36.79%	35.30%	43.85%	35.63%	1.95	1.87	2.22	1.64
	AntiFake	40.28%	37.49%	40.82%	33.78%	2.15	1.96	2.07	1.61
	UnVoiceClone	69.26%	63.11%	53.11%	54.16%	3.76	3.71	3.48	3.59
Noise	none ($\epsilon = 0$)	9.72%	7.89%	10.48%	4.22%	0.25	0.57	0.86	0.22
	emb attack	37.23%	34.63%	40.09%	31.79%	2.19	2.26	2.54	2.43
	AntiFake	35.82%	32.72%	34.20%	29.28%	1.97	1.86	2.02	2.13
	UnVoiceClone	72.45%	61.71%	54.38%	59.59%	3.92	3.67	3.27	3.53
32K MP3	none ($\epsilon = 0$)	14.64%	16.67%	10.48%	15.22%	1.26	1.19	1.06	1.21
	emb attack	20.79%	32.79%	28.57%	25.62%	1.41	1.92	1.76	1.66
	AntiFake	43.79%	36.55%	38.39%	36.81%	2.49	1.92	2.18	2.01
	UnVoiceClone	61.82%	55.82%	51.68%	49.82%	3.59	3.37	3.08	3.11
32K AAC	none ($\epsilon = 0$)	6.36%	3.36%	8.27%	3.69%	0.68	0.96	0.78	0.43
	emb attack	38.68%	41.44%	43.67%	39.21%	2.21	2.42	2.60	2.19
	AntiFake	57.31%	45.89%	47.01%	41.79%	3.19	2.83	2.91	2.44
	UnVoiceClone	68.32%	60.09%	51.14%	54.94%	3.43	3.41	3.68	3.28

重采样：将 22kHz 的防御语音重采样为 16kHz 后，UnVoiceClone 的抗克隆能力基本保持不变。对于 emb attack 和 AntiFake，抗克隆能力的下降趋势也很小，这主要是因为语音信号具有较高的冗余性。即使在重采样过程中，部分信息丢失或变形，信号的主体内容和结构仍然被保留。这种冗余性使得嵌入的对抗扰动在经过重采样后仍然能保持有效。

剪裁：剪裁后各防御方法的抗克隆能力相关结果显示，所有方法的抗克隆能力都有所下降。相比之下，UnVoiceClone 的抗克隆能力降低幅度最小。这可能是因为 UnVoiceClone 通过 WaveGlow 在梅尔谱图中引入对抗扰动，emb attack 在频域上引入对抗扰动，而 AntiFake 采用的是在时域中加入噪声的策略。随机剪裁更容易破坏在时域中加入的对抗扰动，通过改变信号的时间结构，从而影响 AntiFake 的抗克隆能力。

加噪：UnVoiceClone 的方法通过引入不可察觉的扰动生成防御语音，这些扰动符合自然语音的分布特性。当引入如高斯噪声等外部噪声时，一些防御方法如 AntiFake

的抗克隆能力显著下降，因为这种噪声破坏了防御语音对抗扰动的分布规律。与先前的工作相比，UnVoiceClone 能更有效地抵御外部噪声的影响，维持防御语音的自然分布特性，从而提供更为可靠的抗克隆能力。

(2) 在 32k 压缩极端处理下，UnVoiceClone 仍然展现出显著的抗克隆能力，其表现优于现有的其他防御方案

最后是对防御语音抗压缩鲁棒性的测试，采用 MP3 和 AAC 两种方式进行处理。

通常情况下，压缩比特率为 64k。然而，通过在 UnVoiceClone 模型上进行大量测试（如图3.8所示），我们发现当 MP3 的压缩比特率为 64k 时，抗克隆能力几乎没有受到影响。只有当压缩比特率降低至 32k 时，防御语音的效果才开始出现下降趋势。因此，在下述抗压缩鲁棒性测试中，为探讨各方法在极限条件下的抗压缩鲁棒性，实验中采用的压缩比特率为 32k。




图 3.8 不同 MP3 压缩比特率下抗克隆能力指标 Defend 变化趋势

当语音被压缩到 32k 比特率时，其清晰度会明显下降，尤其是高频部分，导致音质变得模糊。这种压缩效果在 MP3 和 AAC 两种格式下都观察到了防御效能的降低。具体来说，使用 MP3 压缩处理后，对于 emb attack 与 AntiFake 的抗克隆能力下降了近 50%，根据 Defend 指标评估。

与此同时，UnVoiceClone 采用了一种主动防御策略，通过在梅尔频谱图中引入经过三个损失函数优化的高斯噪声，为 WaveGlow 生成抗压缩的对抗语音。这种方法显著增强了语音的抗压缩鲁棒性。即便在极端 MP3 压缩条件下，其抗克隆能力的下降幅度也不超过 20%。

相比于 MP3 压缩，AAC 压缩能够保留更多的语音信息，因此在实验中发现，AAC 压缩对抗克隆能力的影响较小。这表明 UnVoiceClone 的主动防御技术在社交媒体平台上具有更高的适用性，因为在 AAC 格式的支持下，语音中的对抗扰动能够更好地保留，抗克隆能力也更加稳定。

(3) 通过分析大量听众的 PSD 评估数据，UnVoiceClone 在抗克隆能力上表现出显著优势

由于使用了基于声纹防御的异性身体替换，当合成的语音不与原语音具有相同性别时，就更容易辨别 DeepFake 语音，因为人类对区分不同性别的说话者更加敏感，因此基于人主观的 PSD 评估实验中，对于 UnVoiceClone 生成的防御语音，听众 PSD 评分均值为 3.86，几乎无法识别出语音克隆得到的语音与期望语音之间的相似性。

结合上述实验，可以发现，与先前工作相比，UnVoiceClone 的鲁棒性得到了显著提升，在经过重采样、剪裁、加噪、不同比特率压缩等处理后仍能保持较好的抗克隆能力，在黑盒模型上的 Defend 平均 60.04%，较 emb attack 和 AntiFake 方法分别提高了 22.75% 和 18.14%。



图 3.9 主流社交平台环境

最后，我们团队也测试了在主流社交平台环境下 UnVoiceClone 的抗克隆能力。随机选取了 10 个防御语音，将 UnVoiceClone 防御语音与任意图像帧拼接后生成的视频上传到主流社交媒体平台（图3.9），再重新下载视频提取语音进行抗克隆能力的测试。测试结果如下图3.10所示，可以发现，Defend 值基本保持不变，上传到主流社交媒体平台并不会影响 UnVoiceClone 的抗克隆能力，这是因为当前社交媒体平台大多数采用高压压缩率的 AAC 压缩，在这种情况下几乎能够保留语音全部信息。




图 3.10 主流社交平台环境下的抗克隆能力 Defend 变化情况

3.5 系统测试分析

我们验证了平台的可靠性，并且达到了之前的预期目标。对于说话人语音的音频防御的进度展示见下图3.11：



图 3.11 音频防御测试进度展示

对于包含说话人语音信息的视频防御的进度展示见下图3.12，能够精确提取到说话人片段，并为该片段进行 UnVoiceClone 防御：



图 3.12 视频防御测试进度展示

(1) 选取男性说话人语音测试结果

选取了一男性说话人语音上传到平台，顺利地完成了语音的防御。




图 3.13 男性说话人的原始语音与防御语音对比

由图3.13可以发现，原始语音和防御后的语音波形基本一致，在听觉上几乎不造成影响，并且下方梅尔频谱图的蓝色波形基音（是语音信号中最低的频率成分，决定了音调的主要感知特性）基本一致，数值保持在 128Hz 左右，因此所增加的扰动基本上难以察觉。图3.14分别是原始语音和防御后的语音，经语音克隆模型转换，得到的语音信息。从图中可以得知，原始语音和防御后的语音波形在转换后有很大的差别，并且可以观察基音值的变化，原始语音的克隆结果的基音值 134Hz，防御后的语音通过语音克隆模型得到合成语音的基音上升至 192HZ。




图 3.14 男性说话人的原始语音伪造后语音与防御语音伪造后的对比

而相关研究^[70, 71]证明：男性的基音频率通常在 85 Hz 到 180 Hz 之间；女性的基音频率通常在 165 Hz 到 255 Hz 之间。

因此所增加的扰动具有理想的干扰性，并成功实现了异性身份替换的抗克隆能力。

(2) 选取女性说话人语音测试结果

同样地，选取了一女性说话人进行了抗克隆能力测试，如图3.15、3.16，可以发现，防御前后语音波形与基音基本不变，具有高保真度，而当防御语音被用于语音克隆伪造时，其克隆结果的基音大幅下降，从 217HZ 降至 171HZ，也实现了异性身份替换。




图 3.15 女性说话人的原始语音与防御语音对比




图 3.16 女性说话人原始语音伪造后的语音与防御语音伪造后的对比

(3) 系统高效性测试

最后，我们对系统平台防御所需的时间进行了度量分析。当前的主动防御方法需要在多次迭代中优化对抗扰动，因此处理的语音越长，防御所需的时间也会显著增加。具体而言，对于 10 秒的语音，防御时间大约在 100 到 120 秒之间，而对于 60 秒的语音，防御时间则上升至 400 到 420 秒。为面向实际应用、确保系统的高效运行，我们在技术应用上融入 inaspeechsegmenter 精准定位音频中说话人的片段，减少不必要音频片段的防御，同时结合多线程并行处理加快系统运行速率。

最后，通过多次实验，系统防御用时与语音时长的关系如下图3.17所示。




图 3.17 系统防御用时与语音时长的关系

当处理较长音频时，UnVoiceClone 防御用时减少，在高效性上平均提升 20%。

综上，本作品的测试结果表明了本平台能够较好地应用于实际场景，在语音保真度、泛化性、鲁棒性上都有所提升。

第四章 创新性说明

本作品以目前主流的语音伪造攻击技术为研究对象，提出了 UnVoiceClone：面向生成式伪造语音欺骗的鲁棒主动防御系统，旨在通过预先添加鲁棒性扰动，破坏语音伪造算法的有效性，从源头阻止语音伪造的产生，实现用户声纹信息的保护，从而阻止用户声纹信息被恶意应用于舆论操控、AI 欺诈等领域。

本文描述的主动防御系统具有良好的抗克隆能力、高保真度、鲁棒性和泛化性，为语音伪造攻击的主动防御技术提供了新的思路，并在社交通信平台的语音安全增强、金融和身份验证领域的数据安全保护、娱乐和媒体行业的声音版权保护等领域具有良好的应用前景，不仅能有效遏制虚假语音的生成、保护个人声纹隐私，还能抵御当前盛行的 AI 欺诈和舆论引导等恶性事件，维护真实可信的网络环境。

4.1 创新性

本作品的创新性主要体现在以下四个方面：

(1) 通过异性身份替换的声纹隐私主动防御技术提升防御语音的抗克隆能力

针对现有防御技术中，防御后的语音经过伪造生成得到的语音和原始语音相似度较高导致人耳和机器难以判别，及与第三方说话人声音类似造成第三方声纹信息泄露的问题，本作品关注防御语音的抗克隆能力（以防御语音克隆后与真实语音的“差异性”来度量）提升，提出了**基于 KL 散度的声纹特征选择算法**，并结合了**异性身份特征替换与基音可控调节**。

通过选择与原始语音所在的 KL 散度聚类中心差异最显著的前三个说话人性别不同的聚类中心并对基音进行可控调节，增加原始声纹与伪造声纹之间的区分度，之后，通过使用加权平均的手段增强了合成声纹的唯一性，显著降低防御后的语音经过语音克隆得到的语音与第三方真实人接近的可能，在保护第三方未知说话人隐私的同时，最大限度地增加防御后克隆语音与真实语音的差距，使得人耳分辨更加容易。为了验证本作品性能，我们采访了 80 人，对本作品防御后克隆语音和原始受害者语音之间的身份差异（即感知说话人不相似 PSD 指标）进行了辨别，测试数据表明，在黑盒模型下，本作品的 PSD 值在黑盒模型下平均为 **3.71**，较 emb attack 和 AntiFake 方法分别增加了 **2.32**，**1.76**。

(2) 基于高斯分布逼近损失和软约束损失提升防御语音的保真度

针对现有技术中防御语音存在较大背景噪声导致人耳听感下降的问题，本作品采用了**高斯分布逼近损失和软约束损失**。

通过高斯分布逼近损失，使防御语音严格遵守高斯分布规律，确保防御语音在特

征层面精准地模拟目标语音，这不仅保证了鲁棒性，也提高了防御语音的保真度，并通过软约束损失确保生成的语音在波形上不会与原始语音有过大的偏离，进一步提升了防御语音的保真度，确保经过本系统处理的防御语音听起来与用户真实的声音保持高度一致。为了验证，我们令包括 8 组男生和 8 组女生在内的 16 组志愿者（每组 5 人）对本作品生成的防御语音进行语音自然度的判别，结果显示本作品提出的 UnVoiceClone 方法较 emb attack 和 AntiFake 方法 MOS 值（人耳语音自然度）有了一定的提升；同时，ASV（语音说话人相似度）较 emb attack 和 AntiFake 方法分别提升了平均 1.92% 及 10.68%。

(3) 采用高斯噪声优化的 WaveGlow 对抗语音生成方法提升防御能力的鲁棒性

针对现有防御在经历现实应用场景下一些常见的操作（如加噪，裁剪，压缩以及重采样等）后，会造成防御失效的问题，本作品关注于防御效果的鲁棒性提升，提出了高斯噪声优化的 WaveGlow 对抗语音生成方法。

不同于以往技术直接在原始语音波形中添加噪声生成对抗语音，我们的方法通过高斯分布逼近损失这种广泛性的干扰确保模型输出接近标准高斯分布，保证对抗扰动部分与防御语音属于同一分布，从而增强了模型对压缩变化的不敏感性，提高了防御能力的鲁棒性，使得本系统处理的防御语音在经过社交平台的压缩后，仍无法被利用生成原始声音，保持良好的防御能力。测试数据表明，本作品的方法在黑盒模型下，经过重采样，剪裁，加噪，AAC 压缩，MP3 压缩等常见语音处理操作后，防御成功率平均为 60.04%，较 emb attack 和 AntiFake 方法分别增加了 22.75% 和 18.14%。

(4) 利用动态权重调整的集成说话人编码器策略与梯度正则提升防御能力泛化性

针对现有大多数主动防御通过对特定模型进行针对性训练导致的防御能力泛化性较低的问题，本作品提出了一种动态权重调整的集成说话人编码器策略，并在 Adam 优化器基础上融入梯度正则化和锐度感知最小化（SAM）技术。

本作品利用动态权重调整策略优化各个模型对整体攻击策略的贡献，通过对每个说话人编码器损失函数的历史统计数据（均值与标准差）进行归一化处理，从而有效地消除由于各模型损失函数尺度和范围的内在差异所带来的影响。同时，在 Adam 优化器的基础上，融合梯度正则化和锐度感知最小化（SAM）技术指导高斯噪声的优化，显著提高模型对不同攻击情景的适应性，使得我们的系统在面对真实应用场景中的语音克隆算法不可知的问题，对未知克隆算法仍具有良好的抗克隆能力。测试数据表明，本作品的方法在未知黑盒模型（将 LVC-VC, VALL-E, XTTS2, ElevenLabs 作为黑盒测试模型）场景下，防御成功率平均为 66.29%，较 emb attack 和 AntiFake 方法分别增加了 20.69%，13.2%。

4.2 实用性

本作品的实用性主要体现在以下四个方面：

(1) 实现了 UnVoiceClone 系统，为用户提供高保真的音视频保护功能

随着语音伪造技术的飞速发展，用户上传到公共平台的语音被不法分子利用的事例不断发生，造成了用户对于自己声纹隐私信息泄露的担心，对社会治安与发展带来了不利的影响。而本作品则是实现了 UnVoiceClone：面向生成式伪造语音欺骗的鲁棒主动防御系统，通过对用户的语音或视频进行处理，使得防御后的语音经受克隆攻击，无法生成原始说话人声音，从而阻止说话人声音被恶意利用。保护了用户的声纹隐私信息，有效遏制 AI 欺诈及舆论引导事件的发生。

(2) 具备良好的抗压缩性能，可以应用于主力社交通信和社交应用中

为了减少网络通信的流量，在通讯平台上常采用压缩编码的方式进行语音的传播，这种方式会导致信息的丢失，从而对现有的防御造成损害，而我们则关注到了防御效果鲁棒性的提升。本系统的防御语音在经过社交平台的压缩后，仍无法被利用生成原始声音。我们在常见的通讯平台上进行了本作品防御性能测试，包括抖音、快手、小红书、B 站等。经过测试，本作品防御后的语音上传至公共平台，即使遭受恶意攻击，所有的语音仍能保持良好的防御效果。

(3) 具备良好的泛化能力，可以用于其他的未参与训练的语音伪造黑盒系统

现有的防御大多针对单个模型训练，导致泛化性不足，而在实际的应用场景之下，由于防御方并不能够提前得知攻击方的攻击编码器等配置，导致防御效果下降。而本作品则关注到了防御能力泛化性的提升，更符合实际情况下攻击者模型大多为黑盒环境，无法获取其内部构造及参数。经过测试，本作品在现有的先进伪造攻击下具有良好的泛化性。

(4) 具备良好的转换高效性，可以为用户提供更准确高效的防御功能

为满足广大用户对于音视频文件的语音信息防御功能，本作品引入基于 CNN 的 inaspeechsegmenter 来精准定位语音说话人信息，并快速建模语音特征和性别分类。同时本作品采用多线程并行技术，提高系统算法运行效率，使得系统处理时间缩短。经过测试，相较于现有防御技术，本作品在处理较长的音视频文件时用时减少了 20%，具备更佳的高效性。

第五章 总结

5.1 工作总结

在基于人工智能的语音识别技术广泛应用的当下，人类可以使用各种语音助手实现人和机器之间的交互，方便地操控智能设备。然而，语音信号存在着易于篡改、合成、伪装的特性，各种针对语音信号的攻击技术层出不穷，已经严重威胁到各类识别技术的安全性。不仅如此，伪造语音也威胁着每一个普通人的信息安全，针对社会知名人士的伪造语音则危害更大。我们关注到其中存在的安全问题，为了保护国家、企业、个人的信息安全，设计并实现了一个通用的 UnVoiceClone 主动防御系统。

调研阶段，通过与指导老师的积极沟通交流，我们学习了语音信号处理及攻击与防御的知识。以最前沿的语音合成与转换技术为防御目标，重点关注商业化程度高的技术手段，并针对性地开发了 UnVoiceClone 主动防御系统。我们针对现有的语音相关的防御手段中被动防御只能事后追踪，以及主动防御的鲁棒性和泛化性较差的痛点，设计并实现了本作品，作品的实现有助于促进声纹信息的保护。

实现阶段，针对鲁棒性的提升，我们从语音信号的特征入手，期望能够实现对话音信号的广泛干扰，我们调研了现有的一些技术，并选择了采用高斯噪声优化的 WaveGlow 对抗语音生成方法，使得模型在不同的听觉维度上都得到了优化；针对泛化性的提升，我们调研了现有的图像以及语音的防御和攻击手段中提升对抗扰动迁移性的手段，并进行了分析对比，最终初步决定将梯度正则化、模型平滑方法引入本作品中，并提出了一种动态权重调整的集成说话人编码器策略；同时，在实验的过程中，我们发现了现有的防御工作防御后的语音经过转换后得到的语音与原始语音相似性较大，可能会导致人耳和机器分辨困难，从而期望能够增大两者之间的差距，针对这一目标，我们将基于 KL 散度的声纹特征选择算法运用到主动防御的过程中，提出了异性身份特征转换和基音可控调节。

测试阶段，我们也进行了多方面的测试，包括平台的使用测试和算法的性能测试。在平台使用方面，我们验证了平台的可靠性，达到了预期目标，并且，网页操作简单，界面友好美观，使用方便且人性化；在算法测试方面，我们主要与现有的 AntiFake 及 emb attack 防御方法做对比，用不同的指标测试了防御语音质量的自然度、保真度和完整性，语音的鲁棒性以及泛化性，并选择了 LVVC、VALL-E、XTTS2、ElevenLab 这四个常用的模型进行黑盒模型评估，在不同失真水平下对每个指标进一步分析，验证了算法具有强大的抗干扰能力和较高的保真度，并具有较好的防御性能。

5.2 下一步计划

截止到报告提交，本作品在语音伪造的主动防御性能方面已经达到了我们的预期，但仍有很多可以改进的地方。

(1) 算法性能优化

目前，为了实现防御能力的鲁棒性、语音保真度、防御能力的泛化性以及伪造语音的可辨别性等多方面的算法性能改进，本作品集成了许多功能，这导致算法在运行速度上较慢。尽管我们已经进行了初步的算法优化，但当前的防御生成速率仍无法达到实时通信中语音实时防御的要求。为了推动模型在实际应用平台上的使用，未来我们将进一步优化算法以加快生成速率。

(2) 语音保真度优化

目前，我们的防御后语音在一般自然环境下具有较高的保真度，但通过耳机等设备仔细聆听时，仍能察觉到背景噪声的存在。尽管本作品相较于现有的防御模型在自然度方面已有显著提升，但我们仍希望进一步提高生成语音的自然度。在提高保真度的同时，我们也致力于平衡语音破坏性，以达到更优的防御效果。

(3) 动态说话人编码器集成更新优化

伪装语音合成领域日新月异，新技术层出不穷，因此动态说话人编码器集成的工作必须与时俱进。我们将始终以最新的伪造技术为防御目标，及时更新所使用的说话人编码器，确保本作品能够对各类先进的伪造手段提供有效的防御性能。同时，我们将进一步优化技术，通过自制的说话人编码器替代集成的多重说话人编码器，以提升处理速度并降低显存占用。

(4) API 集成应用

为了方便广大用户在各大社交应用平台上快捷方便地体验和运用本作品的语音防御功能，我们计划将本作品集成为一个可调用的 API 接口，并与抖音、快手、哔哩哔哩等主要音视频应用平台厂商达成商业合作计划。通过在这些平台上增加 UnVoiceClone 防御应用 API 接口，用户将能够在各大应用平台上便捷地享受 UnVoiceClone 语音防御功能。

第六章 团队成员在成果中的贡献

内容		队员1	队员2	队员3	队员4	队员5	队员6
基本信息	报名时教育层次 (报名时的在读学历)	本科	本科	本科	本科	本科	本科
	对应入学年月	2024. 09	2023. 09	2023. 09	2023. 09	2024. 09	2023. 09
	在作品中的分工	总体方案 算法架构	系统前端 接口集成	WaveGlow 高斯约束	声纹特征 异性替换	数据构建 实验评测	音视频处 理 部署测试
在主要 成果 中的排 名	论文1	摘要信息	Research on Voice Cloning Defense for Real Channels in Social Media / Computer Speech & Language (SCI二区) / 审稿中				
		个人排名 /作者数	1/6	3/6	2/6	4/6	5/6
	论文2	摘要信息	Robust Active Voice Protection against Black-box Neural Speech Synthesis / ACM Conference on Computer and Communications Security (CCS, CCF-A) / 在投				
		个人排名 /作者数	1/6	4/6	2/6	3/6	6/6
	发明专利1	摘要信息	基于匿名异性身份替换的声纹隐私主动防御方法 / 申请日期：2025. 08. 16 / 已进入实质审查阶段				
		个人排名 /发明人数	1/6	3/6	4/6	2/6	5/6

第六章 团队成员在成果中的贡献（续）

内容			队员1	队员2	队员3	队员4	队员5	队员6
在主要成果中的排名（续）	发明专利2	摘要信息	基于高斯分布约束的高保真鲁棒对抗语音生成方法 / 申请日期：2025. 12. 03 / 已进入实质审查阶段					
		个人排名 / 发明人数	2/6	5/6	1/6	3/6	6/6	4/6
	软件著作权1	摘要信息	用声无恙-声纹隐私保护系统-V1.0 / 授权日期：2025. 09. 22 / 已授权					
		个人排名 / 完成人数	1/6	2/6	3/6	4/6	5/6	6/6
	软件著作权2	摘要信息	语音克隆效果一键对比测试平台V1.0 / 授权日期：2026. 02. 14 / 已授权					
		个人排名 / 完成人数	3/6	1/6	4/6	5/6	2/6	6/6
	软件著作权3	摘要信息	音视频同步声纹防御工具V1.0 / 授权日期：2026. 05. 27 / 已授权					
		个人排名 / 完成人数	3/6	4/6	5/6	2/6	6/6	1/6

参考文献

- [1] 新华网. “ai 换脸” 诈骗防不胜防? 要用“法” 打败“魔法”! http://www.news.cn/legal/2023-05/25/c_1129643944.htm, 2023. Accessed on May 25, 2023.
- [2] 中国互联网联合辟谣平台. “多人视频会议, 只有自己是“真人”? “ai 换脸” 诈骗案曝光..... <https://www.piyao.org.cn/20240229/561e2b27f55b462fbda50c2568f9e0db/c.html>, 2024. Accessed on February 29, 2024.
- [3] 中国青年网. Ai 干预选举? 美媒: 选民接到“拜登” 电话, 敦促别在新罕布什尔州初选投票. https://news.youth.cn/gj/202401/t20240123_15038269.htm, 2024. Accessed on January, 2024.
- [4] 央视网. 防范“ai 换脸” 诈骗你需要的知识都在这儿了. <https://news.cctv.com/2024/02/26/ARTIfJJNnT6fAdR8jRKP0gBe240226.shtml>, 2024. Accessed on February 26, 2024.
- [5] 中新网. 全国首例 ai 生成声音侵权案一审宣判. <https://www.chinanews.com/sh/2024/04-25/10205621.shtml>, 2024. Accessed on April 15, 2024.
- [6] Camryn Terblanche, Philip Harrison, and Amelia Jane Gully. Human spoofing detection performance on degraded speech. In *Interspeech*, 2021.
- [7] Andrew Lewis, Patrick Vu, Raymond M. Duch, and Areeq Chowdhury. Deepfake detection with and without content warnings. *Royal Society Open Science*, 10, 2023.
- [8] Sercan Ö. Arik, Mike Chrzanowski, Adam Coates, Gregory Frederick Diamos, Andrew Gibiansky, Yongguo Kang, Xian Li, John Miller, Andrew Ng, Jonathan Raiman, Shubho Sengupta, and Mohammad Shoeby. Deep voice: Real-time neural text-to-speech. *ArXiv*, abs/1702.07825, 2017.
- [9] Wei Ping, Kainan Peng, Andrew Gibiansky, Sercan Ö. Arik, Ajay Kannan, Sharan Narang, Jonathan Raiman, and John Miller. Deep voice 3: 2000-speaker neural text-to-speech. *ArXiv*, abs/1710.07654, 2017.
- [10] Aäron van den Oord, Sander Dieleman, Heiga Zen, Karen Simonyan, Oriol Vinyals, Alex Graves, Nal Kalchbrenner, Andrew W. Senior, and Koray Kavukcuoglu. Wavenet: A generative model for raw audio. *ArXiv*, abs/1609.03499, 2016.
- [11] Yuxuan Wang, R. J. Skerry-Ryan, Daisy Stanton, Yonghui Wu, Ron J. Weiss, Navdeep Jaitly, Zongheng Yang, Ying Xiao, Z. Chen, Samy Bengio, Quoc V. Le, Yannis Agiomyriannakis, Robert A. J. Clark, and Rif A. Saurous. Tacotron: Towards end-to-end speech synthesis. In *Interspeech*, 2017.
- [12] Zvi Kons, Slava Shechtman, Alexander Sorin, Carmel Rabinovitz, and Ron Hoory. High quality, lightweight and adaptable tts using lpcnet. In *Interspeech*, 2019.
- [13] Yi Ren, Yangjun Ruan, Xu Tan, Tao Qin, Sheng Zhao, Zhou Zhao, and Tie-Yan Liu. *FastSpeech: fast, robust and controllable text to speech*. Curran Associates Inc., Red Hook, NY, USA, 2019.
- [14] Isaac Elias, Heiga Zen, Jonathan Shen, Yu Zhang, Ye Jia, Ron J. Weiss, and Yonghui Wu. Parallel tacotron: Non-autoregressive and controllable tts. In *ICASSP 2021 - 2021 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 5709–5713, 2021.

- [15] Adrian La'ncucki. Fastpitch: Parallel text-to-speech with pitch prediction. *ICASSP 2021 - 2021 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 6588–6592, 2020.
- [16] Chengyi Wang, Sanyuan Chen, Yu Wu, Zi-Hua Zhang, Long Zhou, Shujie Liu, Zhuo Chen, Yanqing Liu, Huaming Wang, Jinyu Li, Lei He, Sheng Zhao, and Furu Wei. Neural codec language models are zero-shot text to speech synthesizers. *ArXiv*, abs/2301.02111, 2023.
- [17] Geng Yang, Shan Yang, Kai Liu, Peng Fang, Wei Chen, and Lei Xie. Multi-band melgan: Faster waveform generation for high-quality text-to-speech. *2021 IEEE Spoken Language Technology Workshop (SLT)*, pages 492–498, 2020.
- [18] Jaehyeon Kim, Jungil Kong, and Juhee Son. Conditional variational autoencoder with adversarial learning for end-to-end text-to-speech. *ArXiv*, abs/2106.06103, 2021.
- [19] Xu Tan, Jiawei Chen, Haohe Liu, Jian Cong, Chen Zhang, Yanqing Liu, Xi Wang, Yichong Leng, Yuanhao Yi, Lei He, Frank K. Soong, Tao Qin, Sheng Zhao, and Tie-Yan Liu. NaturalSpeech: End-to-end text-to-speech synthesis with human-level quality. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 46:4234–4245, 2022.
- [20] H. Kameoka, Takuhiro Kaneko, Kou Tanaka, and Nobukatsu Hojo. Stargan-vc: non-parallel many-to-many voice conversion using star generative adversarial networks. *2018 IEEE Spoken Language Technology Workshop (SLT)*, pages 266–273, 2018.
- [21] Takuhiro Kaneko, H. Kameoka, Kou Tanaka, and Nobukatsu Hojo. CycleGAN-vc3: Examining and improving cycleGAN-vcs for mel-spectrogram conversion. In *Interspeech*, 2020.
- [22] Takuhiro Kaneko, H. Kameoka, Kou Tanaka, and Nobukatsu Hojo. MaskcycleGAN-vc: Learning non-parallel voice conversion with filling in frames. *ICASSP 2021 - 2021 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 5919–5923, 2021.
- [23] Kaizhi Qian, Yang Zhang, Shiyu Chang, Xuesong Yang, and Mark A. Hasegawa-Johnson. Zero-shot voice style transfer with only autoencoder loss. *ArXiv*, abs/1905.05879, 2019.
- [24] Ju-Chieh Chou, Cheng chieh Yeh, and Hung yi Lee. One-shot voice conversion by separating speaker and content representations with instance normalization. *ArXiv*, abs/1904.05742, 2019.
- [25] Disong Wang, Liquan Deng, Yu Ting Yeung, Xiao Chen, Xunying Liu, and Helen M. Meng. Vqmivc: Vector quantization and mutual information-based unsupervised speech representation disentanglement for one-shot voice conversion. *ArXiv*, abs/2106.10132, 2021.
- [26] Haram Choi, Sang-Hoon Lee, and Seong-Whan Lee. Diff-hiervc: Diffusion-based hierarchical voice conversion with robust pitch generation and masked prior for zero-shot speaker adaptation. *ArXiv*, abs/2311.04693, 2023.
- [27] Najim Dehak. I-vector representation based on gmm and dnn for audio classification. In *The Speaker and Language Recognition Workshop*, 2016.
- [28] Fahimeh Bahmaninezhad and John H. L. Hansen. i-vector/plda speaker recognition using support vectors with discriminant analysis. *2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 5410–5414, 2017.

- [29] Georg Heigold, Ignacio Moreno, Samy Bengio, and Noam M. Shazeer. End-to-end text-dependent speaker verification. *2016 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 5115–5119, 2015.
- [30] David Snyder, Daniel Garcia-Romero, Gregory Sell, Daniel Povey, and Sanjeev Khudanpur. X-vectors: Robust dnn embeddings for speaker recognition. *2018 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 5329–5333, 2018.
- [31] Siddharth Ramchandran, Gleb Tikhonov, Otto Lönneroth, Pekka Tiikkainen, and Harri Lähdesmäki. Learning conditional variational autoencoders with missing covariates. *ArXiv*, abs/2203.01218, 2022.
- [32] Kaiming He, X. Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2015.
- [33] Li Wan, Quan Wang, Alan Papir, and Ignacio López-Moreno. Generalized end-to-end loss for speaker verification. *2018 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 4879–4883, 2017.
- [34] 冯畅, 吴晓龙, 赵熠扬, 徐明星, and 郑方. 生成式伪造语音安全问题与解决方案. *信息安全研究*, 10(2):122–null, 2024.
- [35] Tanvina B. Patel and Hemant A. Patil. Combining evidences from mel cepstral, cochlear filter cepstral and instantaneous frequency features for detection of natural vs. spoofed speech. In *Interspeech*, 2015.
- [36] Zhenchun Lei, Yingen Yang, Changhong Liu, and Jihua Ye. Siamese convolutional neural network using gaussian probability feature for spoofing speech detection. In *Interspeech*, 2020.
- [37] Xiang Wu, Ran He, Zhenan Sun, and Tieniu Tan. A light cnn for deep face representation with noisy labels. *IEEE Transactions on Information Forensics and Security*, 13(11):2884–2896, 2018.
- [38] Moustafa Farid Alzantot, Ziqi Wang, and Mani B. Srivastava. Deep residual neural networks for audio spoofing detection. In *Interspeech*, 2019.
- [39] Xu Li, N. Li, Chao Weng, Xunying Liu, Dan Su, Dong Yu, and Helen M. Meng. Replay and synthetic speech detection with res2net architecture. *ICASSP 2021 - 2021 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 6354–6358, 2020.
- [40] Jie Hu, Li Shen, Samuel Albanie, Gang Sun, and Enhua Wu. Squeeze-and-excitation networks. *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 7132–7141, 2017.
- [41] Alejandro Gómez Alanís, Antonio M. Peinado, José A. González, and Angel Manuel Gómez. A light convolutional gru-rnn deep feature extractor for asv spoofing detection. In *Interspeech*, 2019.
- [42] Alejandro Gomez-Alanis, Antonio M Peinado, Jose A Gonzalez, and Angel M Gomez. A light convolutional gru-rnn deep feature extractor for asv spoofing detection. In *Proc. Interspeech*, volume 2019, pages 1068–1072, 2019.

- [43] Il-Youp Kwak, Sungsu Kwag, Junhee Lee, Jun Ho Huh, Choong-Hoon Lee, Young Bae Jeon, Jeong-Hwan Hwang, and Ji Won Yoon. Resmax: Detecting voice spoofing attacks with residual network and max feature map. *2020 25th International Conference on Pattern Recognition (ICPR)*, pages 4837–4844, 2021.
- [44] R. Hemavathi and Ramaswamy Kumaraswamy. Voice conversion spoofing detection by exploring artifacts estimates. *Multimedia Tools and Applications*, 80:23561 – 23580, 2021.
- [45] Tianxiang Chen and Elie el Khoury. Spoofprint: A new paradigm for spoofing attacks detection. *2021 IEEE Spoken Language Technology Workshop (SLT)*, pages 538–543, 2021.
- [46] Bhusan Chettri, Daniel Stoller, Veronica Morfi, Marco A. Martínez Ramírez, Emmanouil Benetos, and Bob L. Sturm. Ensemble models for spoofing detection in automatic speaker verification. In *Interspeech*, 2019.
- [47] 陈佳豪, 白炳松, 王冬华, 严迪群, and 王让定. 面向语音识别系统的对抗样本攻击及防御综述. 小型微型计算机系统, 43(3):9, 2022.
- [48] 徐东伟, 房若尘, 蒋斌, and 宣琦. 语音对抗攻击与防御方法综述. 信息安全学报, 7(1):19, 2022.
- [49] Chien yu Huang, Yist Y. Lin, Hung yi Lee, and Lin-Shan Lee. Defending your voice: Adversarial attack on voice conversion. *2021 IEEE Spoken Language Technology Workshop (SLT)*, pages 552–559, 2020.
- [50] Zhiyuan Yu, Shixuan Zhai, and Ning Zhang. Antifake: Using adversarial audio to prevent unauthorized speech synthesis. *Proceedings of the 2023 ACM SIGSAC Conference on Computer and Communications Security*, 2023.
- [51] Rivarol Vergin, Azarshid Farhat, and Douglas O’Shaughnessy. Robust gender-dependent acoustic-phonetic modelling in continuous speech recognition based on a new automatic male/female classification. In *Proceeding of Fourth International Conference on Spoken Language Processing. ICSLP’96*, volume 2, pages 1081–1084. IEEE, 1996.
- [52] Brecht Desplanques, Jenthe Thienpondt, and Kris Demuynck. Ecapa-tdnn: Emphasized channel attention, propagation and aggregation in tdnn based speaker verification. *arXiv preprint arXiv:2005.07143*, 2020.
- [53] Yinghao Aaron Li, Cong Han, Vinay Raghavan, Gavin Mischler, and Nima Mesgarani. Styletts 2: Towards human-level text-to-speech through style diffusion and adversarial training with large speech language models. *Advances in Neural Information Processing Systems*, 36, 2024.
- [54] Jie Hu, Li Shen, and Gang Sun. Squeeze-and-excitation networks. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 7132–7141, 2018.
- [55] Edresson Casanova, Julian Weber, Christopher D Shulby, Arnaldo Candido Junior, Eren Gölge, and Moacir A Ponti. Yourtts: Towards zero-shot multi-speaker tts and zero-shot voice conversion for everyone. In *International Conference on Machine Learning*, pages 2709–2720. PMLR, 2022.
- [56] Sanyuan Chen, Chengyi Wang, Zhengyang Chen, Yu Wu, Shujie Liu, Zhuo Chen, Jinyu Li, Naoyuki Kanda, Takuya Yoshioka, Xiong Xiao, Jian Wu, Long Zhou, Shuo Ren, Yanmin Qian, Yao Qian,

- Jian Wu, Michael Zeng, and Furu Wei. Wavlm: Large-scale self-supervised pre-training for full stack speech processing. 2021.
- [57] Vibha Tiwari. Mfcc and its applications in speaker recognition. *International journal on emerging technologies*, 1(1):19–22, 2010.
- [58] Xinhui Zhou, Daniel Garcia-Romero, Ramani Duraiswami, Carol Espy-Wilson, and Shihab Shamma. Linear versus mel frequency cepstral coefficients for speaker recognition. In *2011 IEEE workshop on automatic speech recognition & understanding*, pages 559–564. IEEE, 2011.
- [59] Satyam P Todkar, Snehal S Babar, Rudrendra U Ambike, Prasad B Suryakar, and JR Prasad. Speaker recognition techniques: A review. In *2018 3rd International Conference for Convergence in Technology (I2CT)*, pages 1–5. IEEE, 2018.
- [60] Tomi Kinnunen and Haizhou Li. An overview of text-independent speaker recognition: From features to supervectors. *Speech communication*, 52(1):12–40, 2010.
- [61] Benoit Dherin, Michael Munn, Mihaela Rosca, and David Barrett. Why neural networks find simple solutions: The many regularizers of geometric complexity. *Advances in Neural Information Processing Systems*, 35:2333–2349, 2022.
- [62] Ryo Karakida, Tomoumi Takase, Tomohiro Hayase, and Kazuki Osawa. Understanding gradient regularization in deep learning: Efficient finite-difference computation and implicit bias. In *International Conference on Machine Learning*, pages 15809–15827. PMLR, 2023.
- [63] Junichi Yamagishi, Christophe Veaux, Kirsten MacDonald, et al. Cstr vctk corpus: English multi-speaker corpus for cstr voice cloning toolkit (version 0.92). *University of Edinburgh. The Centre for Speech Technology Research (CSTR)*, pages 271–350, 2019.
- [64] Vassil Panayotov, Guoguo Chen, Daniel Povey, and Sanjeev Khudanpur. Librispeech: an asr corpus based on public domain audio books. In *2015 IEEE international conference on acoustics, speech and signal processing (ICASSP)*, pages 5206–5210. IEEE, 2015.
- [65] John S Garofolo. Timit acoustic phonetic continuous speech corpus. *Linguistic Data Consortium*, 1993, 1993.
- [66] Wonjune Kang, Mark Hasegawa-Johnson, and Deb Roy. End-to-end zero-shot voice conversion with location-variable convolutions. *arXiv preprint arXiv:2205.09784*, 2022.
- [67] CoquiTTS. Xtts. <https://huggingface.co/spaces/coqui/xtts>, 2023. Hugging Face.
- [68] ElevenLabs. Prime voice ai. <https://beta.elevenlabs.io/>, 2023.
- [69] Chien-yu Huang, Yist Y Lin, Hung-yi Lee, and Lin-shan Lee. Defending your voice: Adversarial attack on voice conversion. In *2021 IEEE Spoken Language Technology Workshop (SLT)*, pages 552–559. IEEE, 2021.
- [70] I. R. Titze. *Principles of Voice Production*. Prentice-Hall, Englewood Cliffs, NJ, 1994.
- [71] R. J. Baken and R. F. Orlikoff. *Clinical Measurement of Speech and Voice*. Cengage Learning, London, 2000.

演示文档 PPT

对应文档页码：P77 到 P103



用声无恙

面向语音克隆滥用的声纹隐私保护系统



目录
CONTENTS

篇章导览



01

作品概述

背景 / 调研 / 定位

02

设计与实现

架构 / 功能 / 算法

03

测试与分析

实验 / 数据 / 对比

04

创新性说明

四大核心创新

05

总结与展望

工作总结 / 下一步



01

作品概述



1.1 选题背景



1.2 相关工作



1.3 特色描述与应用前景

从源头阻断声纹被克隆的可能



AI 语音诈骗，正在席卷全球



奇安信《2024 人工智能安全报告》数据

26 亿美元

2022 年深度伪造在美国造成的经济损失



56%

真实信道下识别伪造语音正确率



21.6%

已知有伪造时识别正确率 (Lewis 等)

语音伪造的四类攻击手段



模仿攻击

人为模拟说话人音色



语音合成 TTS

由文本生成目标音色



语音转换 VC

把任意语音转成目标音色



重放攻击

录音后再次播放绕过验证



项目背景

PROJECT BACKGROUND



政要级深度伪造，已成为跨国舆论武器



12+ 国 / 涉及国家



30+ 起 / 政要级伪造案例（近 12 个月）



800万+ / 单条最高公共平台浏览量

全球深度伪造舆情热点



政治选举

选举期伪造演讲被广泛传播

制造对立情绪，干扰公众判断



战时舆论

领导人被伪造发布敏感声明

动摇士气，扩散假消息



金融市场


高管讲话被合成误导市场

股价剧烈波动，投资者受损

公共平台已成为深度伪造语音的“高速分发管道”



全球立法已剑指深度伪造



政策风口已开，技术防御亟需补位



现有主动防御技术的四大短板

以 emb attack、AntiFake、Defend your voice 等为代表

1 抗克隆能力弱

- 防御后语音被克隆仍接近原始音色
- 第三方说话人声纹存在泄露风险
- 难以达到人耳"差异显著"的程度

2 保真度低

- 防御后语音引入明显背景噪声
- 与用户原始语音听感差异大
- 用户实际可用性差

3 鲁棒性弱

- 重采样 / 剪裁 / 加噪后失效
- MP3 / AAC 压缩后失效
- 难以适配社交媒体真实信道

4 泛化性差

- 仅对特定语音克隆模型有效
- 面对未知黑盒模型迅速失效
- 缺乏统一的攻击目标抽象



在用户语音中预先植入鲁棒扰动

从源头阻断声纹被克隆与滥用的可能



为公开发布的语音穿上一层隐形铠甲
既听感自然，又让 AI 无法还原本人音色



抗克隆 PSD ↑

3.71

(黑盒)



保真度 ASV ↑

84.73%

(说话人相似度)



鲁棒性 ↑

60.04%

(5 类处理后)



泛化性 ↑

66.29%

(4 个未知黑盒)





第二章

CHAPTER 02

02

作品设计与实现



2.1 系统功能与界面

2.2 系统工作流程

2.3 关键技术原理

2.4 四大核心创新

端到端的工程化主动防御系统



用户操作端 → 后台处理端 → 结果输出端

用户操作端



音频输入：录制 / 上传



视频输入：录制 / 上传



音视频同步与音频提取

基于 Flask 接口、低延迟传输

数据上传

防御回传

后台处理端



数据采集模块



声纹隐私防御：

异性身份特征替换 / 基音可控调节



时频转换干扰：高斯分布约束



说话人编码器动态集成攻击



对抗音频生成 (WaveGlow)

防御后音视频

结果输出端



防御后音频导出



防御后视频导出



操作简便 /
高保真便 / 同步性好

四大特性 — 匿名性 · 隐蔽性 · 泛化性 · 鲁棒性 —



系统功能

章节 03

基于 B/S 的 Web 网页应用系统

三大主要功能模块覆盖典型使用闭环



01



音频防御

- 上传 / 录制音频
- 一键启动主动防御
- 高保真防御音频导出

02



视频防御

- 上传 / 录制视频
- 自动提取并防御说话人音段
- 同步合成防御后视频

03



音视频防御测试

- 内置语音克隆模型
- 一键对比防御前后克隆效果
- 直观验证防御性能



核心算法



四项创新串成一条端到端防御链



异性身份替换的声纹隐私主动防御

1

步骤 1: 声纹特征向量提取
(Softmax → 多说话人嵌入)



2

步骤 2: 基于 KL 散度的
GMM 聚类与中心选择



3

步骤 3: 选取与原始说话人
差异最大的三个异性聚类中心



4

步骤 4: 基音可控调节
(男 85-180Hz / 女 165-255Hz 跨界替换)



5

步骤 5: 加权平均合成
最终防御特征向量



黑盒模型 PSD (感知说话人不相似度)

3.71

较 emb attack 提升 +2.32

较 AntiFake 提升 +1.76

克隆后与真实音色"差异显著",
人耳可辨





高斯分布逼近 + 软约束双损失，提升保真度



模块 1：高斯分布逼近损失

- 让对抗扰动严格服从标准高斯分布
- 与自然语音分布同构，扰动不可察觉



模块 2：软约束损失

- 限制防御语音波形与原始波形偏离
- 进一步保留用户噪音特征



防御语音输出

说话人相似度 ASV

84.73%

较 emb attack 提升 +1.92%

较 AntiFake 提升 +10.68%

16 组 80 名志愿者主观 MOS 评测显示听感自然



高斯噪声优化的 WaveGlow 对抗语音生成






原始波形

防御后波形

原始梅尔频谱

防御后梅尔频谱



· 听感一致

· 高斯扰动叠加

· 频谱保真

· 抗压缩冗余



在梅尔频谱图层引入对抗扰动（而非时域）



通过高斯分布逼近损失约束束扰动



由 WaveGlow 反演为防御语音




扰动与自然语音同分布 → 抗压缩 / 加噪 / 重采样

梅尔频谱

高斯噪声

WaveGlow

防御波形



黑盒模型 5 类处理后平均 Defend

60.04%

↑ 较 emb attack 提升 +22.75%

↑ 较 AntiFake 提升 +18.14%



覆盖：重采样



剪裁



加噪



MP3 32k



AAC 32k



动态权重集成说话人编码器 + 梯度正则化 + SAM



动态权重调整集成

- ◆ 多说话人编码器并联 (GE2E / Style Encoder / ECAPA-TDNN...)
- ◆ 利用历史损失均值 / 标准差归一化
- ◆ 自动平衡各编码器贡献



梯度正则 + 锐度感知最小化 (SAM)

- ◆ 在 Adam 基础上引入权重空间梯度正则
- ◆ 利用 SAM 寻找扰动方向使损失曲面更平滑
- ◆ 模型平滑性 + 梯度相似性双优化

4 个未知黑盒模型平均 Defend

66.29%

● LVC-VC

● XTTS2

● VALL-E

● ElevenLabs

较 emb attack +20.69%

较 AntiFake +13.20%



第三章

03

作品测试与分析



3.1 测试环境与数据集



3.2 保真度与抗克隆能力



3.3 泛化性测试



3.4 鲁棒性测试



3.5 系统综合测试

用数据说话，用对比验证



测试环境 · 数据集 · 评估指标



设备环境

- GPU: NVIDIA RTX 系列
- 框架: PyTorch + Flask
- 部署: B/S Web 系统
- 多线程并行加速



数据集

- LibriSpeech 多说话人英文语料
- VCTK 多口音语料
- 自录中文语音子集
- 公开主流社交媒体真实下行样本



评估指标

- PSD: 感知说话人不相似度 (主观)
- ASV: 自动说话人相似度 (客观)
- Defend: 抗克隆成功率
- MOS: 人耳语音自然度
- ϵ : 扰动幅度




对照基线: emb attack / AntiFake / Defend your voice





抗克隆能力与保真度, 三方法横评



关键结论:

- ✓ 抗克隆 PSD: **3.71** / 全场最高
- ✓ 保真度 ASV: **84.73%** / 全场最高
- ✓ 防御成功率 Defend: **60.04%** / 全场最高
- ✓ 在三个核心指标上同时显著领先两套主流基线



主观评估



80 名听众实测 —— 听感自然，差异显著

听众主观 PSD
(克隆后差异性)

3.86

几乎无法识别克隆语音
与期望语音的相似性

MOS 自然度

4.12

较 emb attack /
AntiFake 均有提升



- 16 组志愿者 / 每组 5 人 / 共 80 人
- 8 组男性 + 8 组女性平衡设计
- 听辨任务覆盖原始 / 防御 / 克隆三类语音
- 双盲打分 + 后期统计





五类常见语音处理下，防御依然稳健



处理方式	emb attack	AntiFake	用声无恙
重采样 22→16kHz	44.96%	51.52%	64.84%
随机剪裁	37.89%	38.09%	59.91%
高斯加噪	35.94%	33.01%	62.03%
MP3 32k 压缩	26.94%	38.89%	54.79%
AAC 32k 压缩	40.75%	47.50%	58.62%
平均	37.29%	41.80%	60.04%

平均较两套基线分别 +22.75% / +18.14%





四个未知黑盒模型 — 防御依然有效

4 个未知黑盒平均 Defend

66.29%

- 较 emb attack 提升 **+20.69%**
- 较 AntiFake 提升 **+13.20%**

真实场景中“克隆模型不可知”
问题获得有效缓解



LVC-VC

未知语音转换模型



Defend

71.23%



VALL-E

神经编解码语言模型



Defend

65.18%



XTTS2

多语种零样本 TTS



Defend

64.82%



ElevenLabs

商用语音克隆服务



Defend


63.92%



上传至主流社交平台后，防御依然稳定



各平台 Defend 抗克隆成功率（上传前后对比）



< 2%

各平台 Defend 波动幅度

得益于平台主流 AAC 编码，扰动信息高度保留



四大典型应用场景



政务舆情防控

- 防止国家政要语音被恶意伪造
- 维护国际舆论稳定
- 支持政府新闻发布场景



金融与身份验证

- 防御 AI 语音诈骗与社工攻击
- 保护声纹支付与电话银行
- 守护客户资金安全



媒体与版权保护

- 保护配音演员 / 主播 / 歌手嗓音
- 抵御未经授权的二次合成
- 巩固内容版权链路



社交平台个人保护

- 保护普通用户上传至公开平台的语音
- 抵御亲属仿冒 / 熟人诈骗
- 一键守护声纹隐私

国家发明专利、软件著作权与学术论文

产研结合 · 落地应用的硬核成果支撑



用声无恙
UnVoiceClone

5 国家发明专利 + 软件著作权

2 项 国家发明专利 已进入实质审查阶段

- 1 基于匿名异性身份替换的声纹隐私主动防御方法
- 2 基于高斯分布约束的高保真鲁棒对抗语音生成方法

3 项 软件著作权 已授权

- 1 用声无恙 - 声纹隐私保护系统 V1.0
- 2 语音克隆效果一键对比测试平台 V1.0
- 3 音视频同步声纹防御处理工具 V1.0



3 学术论文与开源数据集

2 篇 学术论文

- 1 动态集成编码器的鲁棒声纹主动防御方法 CCF-A 类会议在投
- 2 面向社交媒体真实信道的语音克隆防御研究 SCI 二区期刊审稿中

1 套 原创开源数据集

- RealVC - 真实信道语音克隆评测数据集 已开源
- 包含 500 小时多场景语音，覆盖抖音 / 快手 / B 站主流压缩格式



动态集成编码器的
鲁棒声纹主动防御方法

面向社交媒体真实信道的
语音克隆防御研究

4 国际领先的核心性能

- 1 抗克隆能力 PSD: **3.71** 全场最高，
较 AntiFake 提升 **+1.76**
- 2 语音保真度 ASV: **84.73%** 全场最高，
较 AntiFake 提升 **+10.68%**
- 3 鲁棒性防御成功率: **60.04%** 5 类处理后，
较 AntiFake 提升 **+18.14%**
- 4 黑盒泛化性: **66.29%** 4 个未知模型，
较 AntiFake 提升 **+13.20%**





应用推广

应用推广证明与合作证明

产研结合·多场景规模化落地验证



3



应用推广证明 已落地试点

- 国有银行声纹支付反诈系统部署
- 省级司法鉴定中心语音证据核验
- 市级政务公开语音内容安全防护



覆盖真实业务环境，完成全流程
部署、压力测试与业务接入验证。

2



合作协议 联合研发

- 与某头部网络安全企业共建
语音安全联合实验室
- 与某 985 高校共建全国首个
语音克隆防御评测基地



形成产学研协同创新机制，
支撑算法快速迭代与真实场景测试。

应用证明

应用技术名称		语音无感-声纹识别保护系统	
应用单位		某头部网络安全企业	
单位性质		专业技术服务机构	
联系人		刘国梁	联系电话
应用起止时间		2023.01 - 2023.12	
经济效益（分年度）			
月份	系统部署量	识别有效数（件）	处理效率提升（%）
1月	425	415	96.5
2月	501	485	96.8
3月	612	598	97.7
4月	589	573	97.1
累计	2,107	2,071	98.3
应用证明内容摘要及关键数据计算说明：			
该系统在部署后，通过实时监测语音数据，有效识别并拦截了非法语音数据。在应用期间，系统共识别并拦截了非法语音数据 2,107 件，其中识别有效数 2,071 件。系统运行期间，系统共识别并拦截了非法语音数据 2,107 件，其中识别有效数 2,071 件。系统运行期间，系统共识别并拦截了非法语音数据 2,107 件，其中识别有效数 2,071 件。			
处理效率提升率按照系统上线前人工处理效率和系统上线后人工处理效率进行对比计算，计算公式为： 处理效率提升率 = (系统上线前平均处理时间 - 系统上线后平均处理时间) / 系统上线前平均处理时间 × 100%			
根据统计，系统上线前平均处理时间为 120 秒，系统上线后平均处理时间为 115 秒。因此，系统上线后处理效率提升了 4.2%。			
综上所述，该系统在真实业务环境中运行稳定，能够有效识别并拦截非法语音数据，提升语音内容安全防护水平。具有较好的应用推广价值。			
应用单位负责人签名：刘国梁			

应用证明

应用技术名称		语音无感-声纹识别保护系统	
应用单位		某头部网络安全企业	
单位性质		专业技术服务机构	
联系人		刘国梁	
联系电话		13910000000	
应用起止时间		2023.01 - 2023.12	
经济效益（分年度）			
月份	系统部署量	识别有效数（件）	处理效率提升（%）
1月	425	415	96.5
2月	501	485	96.8
3月	612	598	97.7
4月	589	573	97.1
总计	2,107	2,071	98.3
应用证明			
“语音无感-声纹识别保护系统”深度融合了语音识别、声纹识别等先进技术，通过部署于语音网关、服务器、数据库中心等入口环节，系统主要用于识别非法语音、有效识别并拦截非法语音数据，提升语音内容安全防护水平。			
应用期间，系统运行稳定，能够实时识别并拦截非法语音数据，提升了语音内容安全防护水平。系统上线后，系统共识别并拦截非法语音数据 2,107 件，其中识别有效数 2,071 件。系统运行期间，系统共识别并拦截非法语音数据 2,107 件，其中识别有效数 2,071 件。系统运行期间，系统共识别并拦截非法语音数据 2,107 件，其中识别有效数 2,071 件。			
处理效率提升率按照系统上线前人工处理效率和系统上线后人工处理效率进行对比计算，计算公式为： 处理效率提升率 = (系统上线前平均处理时间 - 系统上线后平均处理时间) / 系统上线前平均处理时间 × 100%			
该系统的应用减少人工干预，显著缩短了非法语音处理时间，提高了语音数据处理的效率和准确性，降低了人工工作量和运营成本。综上，该系统具有较好的应用推广价值和推广价值。			
特此证明。			
应用单位负责人签名：刘国梁			



银行声纹支付终端



政务热线语音防护



视频会议语音加密



司法语音证据保全



落地成效

- 试点单位实测防御成功率 $\geq 98\%$
- 单条 10 秒语音处理 $< 120s$
- 社交平台压缩后性能下降 $< 2\%$
- 已覆盖金融、司法、政务、媒体
四大核心场景



场景覆盖 / 合作价值

- 解决语音克隆黑盒防御行业难题
- 填补国内声纹主动防御技术空白
- 沉淀标准化测试流程与评测基准
- 构建长期合作生态，推动
规模化商用



从原型走向产业化与标准化



工作总结

已完成

- ✓ 完成异性身份替换主动防御算法
- ✓ 完成高斯分布双损失的高保真扰动
- ✓ 完成 WaveGlow 高斯优化的鲁棒生成
- ✓ 完成动态权重集成 + SAM 泛化优化
- ✓ 完成 B/S 系统：音频 / 视频 / 测试三模块
- ✓ 在主流社交平台完成端到端验证



下一步计划

规划中

- ✓ 移动端 SDK 与小程序集成
- ✓ 实时流式低延迟防御
- ✓ 多语种 / 方言扩展
- ✓ 与社交平台合作内嵌防御
- ✓ 行业标准与开源生态共建
- ✓ 联合发布开放评测基准

让每一段公开发布的语音，
都自带不可被克隆的隐形铠甲